北京交通大學

硕 士 学 位 论 文

基于扩散模型的图像判别任务特征增强算法研究

Research on Feature Enhancement for Image Discriminative Tasks Based on Diffusion Models

作者：许铮睿

导师：黄晓雯

北京交通大学

2026 年 3 月

学位论文版权使用授权书

本学位论文作者完全了解北京交通大学有关保留、使用学位论文的规定。特授权北京交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：　　导师签名：

签字日期：　　年　　月　　日　　签字日期：　　年　　月　　日

学校代码: 10004 密级: 公开

北京交通大学

硕士学位论文

基于扩散模型的图像判别任务特征增强算法研究

Research on Feature Enhancement for Image Discriminative Tasks Based on Diffusion Models

作者姓名: 许铮睿 学 号: 23120435

导师姓名: 黄晓雯 职 称: 副教授

学位类别: 工学 学位级别: 硕士

学科专业: 计算机科学与技术 研究方向: 模式识别与计算机视觉

北京交通大学

2026 年 3 月

致谢

放置在摘要页前，对象包括：1）国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人。2）协助完成研究工作和提供便利条件的组织或个人。3）在研究工作中提出建议和提供帮助的人。4）给予转载和引用权的资料、图片、文献、研究思想和设想的所有者。5）其他应感谢的组织和个人。

摘要

去噪模型作为扩散框架的核心机制，已在生成建模中展现出强大的分布刻画与样本合成能力，但其在判别任务中的潜力仍有待系统挖掘。判别学习本质上依赖表征学习，即学习能够支撑分类与预测的判别性特征；然而真实视觉数据普遍伴随噪声污染、域偏移与背景干扰，容易造成类内离散增大和类间边界模糊。已有扩散思想在判别场景中的应用多针对单一任务，通用性不足，且常需显式递归去噪步骤，导致推理延迟与部署成本上升。围绕“如何在保持计算效率的同时提升特征判别性”这一关键问题，本文以“特征提取—特征去噪”统一建模为主线展开研究。本文的研究内容与主要贡献可归纳为以下两个方面：

（1）面向无额外推理成本的特征增强算法研究：将判别骨干网络中的级联嵌入层解释为逐层去噪过程，实现特征提取与特征去噪的统一建模；进一步构建去噪层与特征层的参数融合机制，给出融合前后严格等价的变换关系，将训练阶段的双分支增强折叠为推理阶段的单分支计算，从而在不改变任务头和参数规模的前提下实现无额外推理成本的特征增强；同时兼容无标签训练与有标签监督训练，使去噪信号与判别信号能够协同优化，并可直接嵌入多类判别框架，迁移成本较低且部署流程简洁。

（2）基于模型蒸馏的特征增强算法研究：针对轻量去噪模块表达能力受限、噪声估计偏差较大的问题，引入教师--学生蒸馏机制，以高容量教师网络提供更稳定的噪声方向监督；提出多轮单层去噪与多步去噪融合策略，在不增加部署复杂度的条件下压缩多步轨迹并增强有限去噪深度下的表征能力；通过消融与对比评估验证蒸馏与融合模块的互补性与稳定收益，使方法在同等预算下获得更强的跨任务泛化性能。进一步地，蒸馏目标与多步融合可统一训练并稳定收敛。

实验覆盖行人重识别、车辆重识别、图像分类、目标检测与语义分割等任务，包含 CNN 与 Transformer 等多类骨干网络以及多个公开数据集，评价指标包括 mAP/Rank-1、Top-1/Top-5、AP 系列指标与 mIoU。结果表明，所提方法在不同骨干与不同任务上均可获得稳定性能增益，并在计算预算受限条件下保持较高效率，验证了方法的工程可部署价值，为扩散思想服务判别式表征学习提供了统一、有效且可落地的技术路径；同时，两类方法可作为可插拔增强模块适配不同判别骨干，为后续面向更复杂开放场景的鲁棒表征学习提供了可复用的技术基础。相关分析进一步表明，该框架在不同噪声强度、训练规模与数据扰动条件下仍保持稳定收益，体现出良好的跨场景适应能力与工程迁移潜力。

关键词：扩散模型；判别式表征学习；特征增强；参数融合；模型蒸馏

ABSTRACT

Denoising models, as the core mechanism of diffusion frameworks, have shown strong capability in generative modeling, yet their value in discriminative learning remains insufficiently explored. Discriminative tasks fundamentally rely on representation learning, i.e., learning features that support accurate prediction and decision-making. In real visual scenarios, however, noise contamination and distribution perturbation often degrade feature discriminability. Existing diffusion-based discriminative approaches are usually task-specific and often require explicit multi-step denoising during inference, making it difficult to jointly satisfy performance gains and deployment efficiency. To address this gap, this thesis studies discriminative feature enhancement from two perspectives, and the main contributions are summarized as follows:

(1) Feature enhancement without extra inference cost: cascaded embedding layers in a discriminative backbone are reinterpreted as progressive denoising stages, enabling unified modeling of feature extraction and denoising. A parameter fusion mechanism is further derived with strict equivalence between pre-fusion and post-fusion forms, so that training-time dual-branch enhancement can be folded into deployment-time single-branch computation. This design delivers computation-free enhancement without changing task heads or model scale, and is compatible with both label-free and label-augmented training for denoising–discriminative co-optimization. Moreover, it integrates into diverse discriminative backbones with low migration cost and a simple deployment workflow, and can be directly plugged into existing industrial inference pipelines.

(2) Feature enhancement via model distillation: to mitigate the limited representational capacity of lightweight denoising modules, a teacher–student distillation scheme is introduced to provide more reliable noise-direction supervision. In addition, multi-round single-layer denoising and multi-step denoising fusion are proposed to compress multi-step trajectories and strengthen denoising depth without increasing deployment complexity. The two perspectives form a progressive framework in which the first addresses deployment efficiency, while the second further improves robustness and generalization under the same computational budget. Furthermore, distillation and multi-step fusion are jointly optimized in one training pipeline for stable convergence while maintaining controllable optimization behavior.

Experiments on person re-identification, vehicle re-identification, image classification, object detection, and semantic segmentation, covering both CNN and Transformer

backbones on multiple public datasets, with metrics including mAP/Rank-1, Top-1/Top-5, AP series, and mIoU, demonstrate consistent gains and favorable efficiency. These results verify strong cross-task generalization and practical deployability, and provide a unified, effective, and actionable pathway for applying diffusion principles to discriminative representation learning, with promising practical and engineering applicability and sustained room for evolution.

KEYWORDS: diffusion model; discriminative representation learning; feature enhancement; parameter fusion; model distillation

序言

随着视觉感知系统在智能交通、公共安全与人机协同等场景中的深入应用，模型在复杂环境下的稳定性与可部署性成为研究重点。作者在前期研究中围绕行人重识别任务开展了持续探索，并进一步将研究边界扩展到分类、检测和分割等典型判别任务。研究过程中逐步形成如下认识：其一，复杂噪声与分布偏移是制约判别模型泛化能力的重要因素；其二，扩散模型具备优良的分布建模与噪声抑制能力，但直接移植到判别任务常伴随推理时延增加；其三，若能在建模阶段引入去噪能力、在部署阶段消除冗余计算，可在性能与效率之间取得更优平衡。

基于上述认识，本文尝试构建“统一建模、等价融合、能力增强”的技术路线，并形成了由基础方法到增强方法的递进式研究框架。论文写作遵循“问题导向、理论支撑、实验验证、工程可用”的组织原则，力求在方法论与应用落地之间建立清晰联系。希望本研究能够为扩散思想在判别学习中的进一步发展提供可复用的分析视角与实践经验。

目录

摘要 iii
ABSTRACT iv
序言 vi
1 引言 1
1.1 研究背景与意义 1
1.2 研究现状与挑战 1
1.3 研究内容与主要贡献 1
1.4 论文结构安排 2
2 相关工作 3
2.1 生成式扩散模型 3
2.2 判别式表征学习 3
2.3 扩散模型在判别任务中的应用 3
2.4 知识蒸馏相关方法 3
2.5 本章小结 4
3 面向无额外推理成本的特征增强算法研究（DenoiseRep） 5
3.1 研究问题与整体框架设计 5
3.2 联合特征提取与特征去噪 5
3.2.1 扩散过程建模 5
3.2.2 去噪网络训练 5
3.3 特征提取与去噪的参数融合 6
3.3.1 双分支结构设计 6
3.3.2 参数融合数学推导 6
3.4 本章实验设计 6
3.4.1 实验设置与评价指标 6
3.4.2 实现细节与训练策略 6
3.5 实验结果与分析 6
3.5.1 基础效果与对比分析 6
3.5.2 效率与开销验证 7
3.6 本章小结 7

4 基于模型蒸馏的特征增强算法研究（DenoiseRep++） 8
4.1 研究问题演进与章节过渡（由 DenoiseRep 到 DenoiseRep++） 8
4.2 教师--学生蒸馏去噪框架 8
4.3 有限去噪深度下的增强策略 8
4.3.1 多轮单层去噪 8
4.3.2 多步去噪融合 8
4.4 无监督与有监督学习范式 9
4.5 本章实验设计 9
4.5.1 消融与模块贡献 9
4.5.2 跨任务实验设置 9
4.6 实验结果与分析 9
4.6.1 蒸馏模块效果 9
4.6.2 多步融合效果 9
4.6.3 跨任务泛化分析 10
4.7 本章小结 10
5 结论与展望 11
5.1 全文工作总结 11
5.2 主要创新点 11
5.3 不足与未来工作 11
参考文献 13
附录 A 14
索引 15
作者简历及攻读硕士学位期间取得的研究成果 16
独创性声明 17
学位论文数据集 18

1 引言

1.1 研究背景与意义

视觉判别任务是计算机视觉研究与产业应用的核心方向，广泛应用于检索、安防、交通与智能交互场景。当前主流模型在标准基准上已取得较高精度，但在真实环境中仍受到遮挡、光照变化、天气扰动和域偏移等因素影响，导致特征判别性下降与性能退化。如何在保证部署效率的前提下提升复杂场景鲁棒性，是当前研究中的关键问题。

扩散模型在生成任务中展现出优异的噪声建模能力，但其在判别任务中的潜力尚未被充分挖掘。将扩散去噪机制迁移到判别式表征学习，有望在不依赖额外标注成本的条件下改善特征质量，为分类、检测、分割与检索任务提供统一增强能力。

1.2 研究现状与挑战

现有相关研究主要集中在三条路径：基于数据增强的鲁棒学习、基于结构设计的特征改进、基于扩散思想的任务特定方法。上述方法分别在抗扰动能力、表示能力和建模范式上提供了启发，但仍存在两类共性不足：

1. 方法往往面向特定任务或特定数据结构，跨任务复用能力有限；
2. 若显式引入多步去噪过程，推理时延容易增加，与实际部署需求冲突。

据此，本文聚焦“通用表征增强”和“计算效率保持”两个目标，探索可部署的扩散去噪判别学习方案。

1.3 研究内容与主要贡献

围绕上述问题，本文完成了以下工作：

1. 提出基础方法 DenoiseRep，将级联嵌入层与逐层去噪过程统一建模，实现特征提取与去噪协同优化；
2. 提出参数融合机制，将训练期去噪分支折叠到推理期主干映射中，实现零额外推理开销；

3. 提出增强方法 DenoiseRep++，引入教师--学生蒸馏与多步融合策略，提升轻量结构下的去噪强度与泛化能力；

4. 在 ReID、分类、检测、分割和车辆重识别任务上完成系统验证，并将实验结果分别纳入对应方法章节。

1.4 论文结构安排

全文结构如下：第1章为引言；第2章综述相关工作；第3章围绕面向无额外推理成本的特征增强算法 DenoiseRep 展开，并在本章内给出实验结果与分析；第4章在此基础上讨论基于模型蒸馏的增强方法 DenoiseRep++，包含研究点过渡、蒸馏与多步融合策略及实验结果；第5章总结全文并展望未来工作。

2 相关工作

2.1 生成式扩散模型

扩散模型通过前向加噪与反向去噪过程学习数据分布，近年来在图像与多模态生成领域取得了显著进展。以 DDPM 为代表的方法将采样过程离散化为多步马尔可夫链，具有良好的训练稳定性与生成质量。随后，DDIM、Progressive Distillation、DPM-Solver 等工作进一步从采样轨迹压缩和数值求解角度降低了推理开销。上述研究表明，扩散框架不仅具备高质量建模能力，也具备较强的噪声估计能力，这为其向判别任务迁移提供了理论基础。

2.2 判别式表征学习

判别任务以学习条件分布 $P(y|x)$ 为目标，高质量表征是分类、检索、检测、分割等任务性能的共同基础。传统方法从手工特征与度量学习出发，深度学习阶段逐步形成以 CNN 与 Transformer 为核心的主流框架。行人重识别领域尤为依赖特征判别性，研究从 ResNet 系列方法扩展到 TransReID、CLIP-ReID 等新范式。尽管性能持续提升，复杂场景下的噪声累积与分布偏移问题仍普遍存在。

2.3 扩散模型在判别任务中的应用

已有研究尝试将扩散思想用于检测与分割等特定任务，例如将检测框逐步去噪或利用扩散注意力图构建零样本分割结果。这些工作验证了扩散思想在判别任务中的潜力，但大多依赖任务特定数据结构，难以直接迁移到通用表征学习框架。同时，多步迭代去噪常引入额外推理时延，与实际部署需求存在矛盾。

2.4 知识蒸馏相关方法

知识蒸馏通过教师网络向学生网络传递软监督信号，可在参数规模受限条件下提升学生模型表达能力。扩散模型领域的渐进式蒸馏表明，多步去噪轨迹可以通过蒸馏压缩到更少步数并保持性能。该思路对本文具有直接启发：在不改变部署复杂度的前提下，利用教师模型提升轻量去噪模块的噪声估计精度，并通过多步信息压缩增强单步推理能力。

2.5 本章小结

本章从生成式扩散模型、判别式表征学习、扩散判别迁移与知识蒸馏四个维度总结了相关研究现状。现有方法在“通用性、效率与去噪强度”之间仍存在明显缺口。下一章将提出基础方法 DenoiseRep，并在方法章内直接给出对应实验验证。

3 面向无额外推理成本的特征增强算法研究（DenoiseRep）

3.1 研究问题与整体框架设计

本章提出基础方法 DenoiseRep，目标是在不增加推理开销的前提下提升判别特征质量。核心思路是将骨干网络的级联嵌入层解释为逐层去噪过程，使特征提取与去噪增强在同一主干内协同完成。与仅在最终输出端附加去噪器不同，该设计能够在层级语义空间中逐步抑制噪声累积。

3.2 联合特征提取与特征去噪

3.2.1 扩散过程建模

设骨干网络共有 N 层嵌入映射，第 n 层特征记为 $\mathbf{h}_n$。本文将各层特征视作扩散建模的样本，构造前向加噪过程，并以层级与时间步对齐的方式设定噪声调度，从而在特征提取流程中引入逐层去噪视角。

3.2.2 去噪网络训练

本文在每层后引入去噪分支 G_n，训练阶段冻结主干参数，仅优化去噪分支。其噪声预测损失写为

$$\mathscr{L}_{denoise} = \mathbb{E}_{\mathbf{h},\varepsilon,t}\left[\|\varepsilon - G_n(\mathbf{h}_{n,t}, t)\|_2^2\right]. \tag{3.1}$$

其中 $\mathbf{h}_{n,t}$ 为第 n 层特征在扩散步 t 下的噪声样本，ε 为高斯噪声。该训练方式同时兼容两类范式：

1. **label-free**：仅优化去噪损失，利用无标签数据学习特征噪声分布；
2. **label-augmented**：将任务损失与去噪损失加权联合，兼顾判别监督与噪声抑制。

3.3 特征提取与去噪的参数融合

3.3.1 双分支结构设计

训练阶段在每层引入去噪分支，与原嵌入层形成双分支结构；推理阶段通过参数融合恢复单分支，实现训练增强与部署高效的统一。

3.3.2 参数融合数学推导

为消除推理阶段额外开销，本文将去噪分支参数折叠进原嵌入层参数。设原层映射为

$$\mathbf{y} = \mathbf{W}\mathbf{x} + \mathbf{b}, \tag{3.2}$$

融合后得到等价映射

$$\mathbf{y}' = \mathbf{W}'\mathbf{x} + \mathbf{b}'. \tag{3.3}$$

其中 $\mathbf{W}'$、$\mathbf{b}'$ 吸收了去噪分支线性修正项。融合后网络保持单分支结构，参数量与计算图复杂度不增加，因而可实现 computation-free 的部署增强。

3.4 本章实验设计

3.4.1 实验设置与评价指标

本章实验聚焦基础方法有效性，采用 Market-1501、DukeMTMC-reID、MSMT17、CUHK-03 四个 ReID 数据集，评价指标为 mAP 与 Rank-1。

3.4.2 实现细节与训练策略

骨干采用 TransReID-SSL 配置，并在相同训练预算下与基线比较。[需要补充具体训练超参与实现细节]

3.5 实验结果与分析

3.5.1 基础效果与对比分析

表3.1显示，DenoiseRep 在四个 ReID 数据集上均实现稳定增益，说明在不改变骨干结构的前提下，特征层去噪能够有效提升表征判别性。

表 3.1　基础方法在 ReID 数据集上的结果

数据集	方法	mAP(%)	Rank-1(%)
DukeMTMC-reID	Baseline	80.40	87.80
DukeMTMC-reID	+DenoiseRep	80.76	88.22
MSMT17	Baseline	66.30	84.80
MSMT17	+DenoiseRep	66.81	85.34
Market-1501	Baseline	91.20	95.80
Market-1501	+DenoiseRep	91.59	96.21
CUHK-03	Baseline	83.50	85.90
CUHK-03	+DenoiseRep	83.69	86.02

进一步实验表明，在引入标签监督后，方法相较仅监督基线仍有额外提升，体现了“监督判别信号 + 无监督去噪信号”的互补性。

在 CNN 与 Transformer 两类主流骨干上，基础方法均呈现一致增益。尤其在中小容量骨干中，提升幅度更明显，说明特征噪声抑制对弱表征模型具有更高边际收益。

3.5.2　效率与开销验证

推理效率实验显示：仅在末层附加去噪分支会引入额外时延，而逐层去噪并执行参数融合后，推理时间与基线基本一致，同时精度保持提升。该结果从工程层面验证了融合机制的有效性。

3.6　本章小结

本章提出了基础方法 DenoiseRep，并在本章内完成了有效性、效率与对比实验验证。结果表明，分层去噪与参数融合可在不增加推理开销的前提下稳定提升判别特征质量。

4 基于模型蒸馏的特征增强算法研究（DenoiseRep++）

4.1 研究问题演进与章节过渡（由 DenoiseRep 到 DenoiseRep++）

在第3章基础方法已满足部署效率要求，但当去噪模块必须轻量化时，其噪声分布建模能力仍存在上限。为进一步提升复杂场景下的去噪强度与泛化性能，本章提出 DenoiseRep++，重点解决“轻量结构表达受限”与“有限去噪深度不足”两个问题，并形成从基础方法到增强方法的自然过渡。

4.2 教师--学生蒸馏去噪框架

设教师去噪器与学生去噪器的噪声预测分别为 $\hat{\varepsilon}_T$、$\hat{\varepsilon}_S$，蒸馏损失定义为

$$\mathscr{L}_{distill} = \|\hat{\varepsilon}_T - \hat{\varepsilon}_S\|_2^2. \tag{4.1}$$

最终训练目标由任务损失、去噪损失和蒸馏损失联合构成：

$$\mathscr{L} = \mathscr{L}_{task} + \lambda_d \mathscr{L}_{denoise} + \lambda_s \mathscr{L}_{distill}. \tag{4.2}$$

该设计在训练阶段利用高容量教师提供更稳定的噪声方向监督，推理阶段仍仅保留融合后的学生主干，不增加部署开销。

4.3 有限去噪深度下的增强策略

4.3.1 多轮单层去噪

在每层参数不增加的条件下，对单层去噪映射执行少量迭代更新，等价于在局部特征空间中延长去噪轨迹。实验中通常 1–3 轮即可获得明显收益，继续增加轮数的边际收益递减。

4.3.2 多步去噪融合

借鉴扩散蒸馏思想，将教师模型的多步去噪结果压缩到学生单步映射。训练期通过多步监督增强学生表示能力，推理期通过参数折叠保持单步执行形式，实现“训练增强、部署不增负担”。

4.4 无监督与有监督学习范式

本章方法同时支持无标签与有标签训练：无监督模式仅优化去噪损失，有监督模式将任务损失与去噪损失联合优化，从而兼顾判别性与鲁棒性。[需要补充具体损失定义与权重设置]

4.5 本章实验设计

4.5.1 消融与模块贡献

本章实验围绕增强模块贡献展开，重点验证蒸馏与多步融合的单独作用及协同增益。

4.5.2 跨任务实验设置

实验覆盖 ReID、分类、检测、分割与车辆重识别任务，常用指标包括 mAP/Rank-1、Top-1/Top-5、AP 系列指标及 mIoU/B-IoU。所有对比在相同骨干和近似训练预算下进行。

4.6 实验结果与分析

4.6.1 蒸馏模块效果

蒸馏模块主要提升单步噪声预测质量。在 ImageNet-1k、MSMT17、COCO、ADE20K 等任务上，加入蒸馏后指标均有稳定增长，说明教师监督可有效缓解轻量去噪层的估计偏差。

4.6.2 多步融合效果

融合模块通过多轮或多步压缩增强去噪轨迹逼近能力，在噪声敏感任务（如 ReID、检测）中提升更明显。其收益来源于对层间噪声累积的抑制和对判别边界的重整。

4.6.3 跨任务泛化分析

蒸馏与融合联合使用时通常取得最佳结果，表明二者分别作用于“单步预测精度”和“有效去噪深度”两个互补维度。

跨任务泛化 在分类、检测、分割和车辆重识别任务上的一致正向增益说明，增强方法并不依赖单一任务结构，而是作用于更通用的特征噪声抑制机制。对于背景复杂或域偏移明显的数据集，性能提升更为突出。

可视化与统计分析 通过 t-SNE 可视化可观察到增强后特征类簇更紧凑、类间边界更清晰。进一步统计类内方差、类间距离及 Inter/Intra 比值，可见增强后类内离散度下降、类间分离度上升，与定量指标提升一致。

公平性对比 为排除“训练轮数增加导致性能提升”的干扰，在相同训练预算下对比基线与增强方法。结果显示基线在延长训练后提升有限，而 DenoiseRep++ 仍保持持续收益，说明改进主要来源于方法本身而非训练时长。

表 4.1 DenoiseRep++ 关键消融结果（示例）

任务	配置	指标 1	指标 2
ImageNet-1k	Baseline	81.82	95.88
ImageNet-1k	+DenoiseRep	82.13	96.06
ImageNet-1k	+DenoiseRep++	82.30	96.19
DukeMTMC-reID	Baseline	81.20	87.80
DukeMTMC-reID	+DenoiseRep	82.10	88.70
DukeMTMC-reID	+DenoiseRep++	82.50	89.10
COCO	Baseline	42.80	65.10
COCO	+DenoiseRep	44.30	67.10
COCO	+DenoiseRep++	44.70	67.40
ADE20K	Baseline	34.10	42.20
ADE20K	+DenoiseRep	34.80	42.50
ADE20K	+DenoiseRep++	35.00	42.60

4.7 本章小结

本章提出 DenoiseRep++ 并在本章内完成模块消融、跨任务泛化、可视化统计和公平性对比验证。结果表明，蒸馏与多步融合能够在不增加部署复杂度的前提下显著提升去噪能力与特征判别性。

5 结论与展望

5.1 全文工作总结

本文围绕复杂视觉场景下判别模型的鲁棒性与可部署性问题，系统研究了扩散思想在判别表征学习中的应用。全文主要完成了以下工作：

1. 提出 DenoiseRep 方法，将级联嵌入层与逐层去噪过程统一建模，实现特征提取与去噪增强协同优化；
2. 设计参数融合机制，将训练阶段去噪分支等价折叠到推理阶段主干映射，实现无额外推理开销的特征增强；
3. 提出 DenoiseRep++ 增强框架，通过教师--学生蒸馏和多步去噪融合提升轻量去噪模块的表达能力；
4. 在 ReID、分类、检测与分割任务上完成系统实验，验证方法在性能提升、跨任务泛化与效率保持方面的综合优势。

5.2 主要创新点

本文的主要创新可归纳为以下三个方面：

1. **统一建模创新**：将扩散去噪机制引入判别表征学习主干，构建了生成思想与判别学习之间的统一桥接框架；
2. **高效部署创新**：提出去噪层与特征层参数融合策略，在理论等价前提下实现训练增强与推理高效的兼容；
3. **能力增强创新**：提出蒸馏与多步融合协同机制，提升了轻量结构在复杂噪声与分布偏移条件下的鲁棒性。

5.3 不足与未来工作

尽管本文方法取得了较稳定的实验增益，但仍存在进一步优化空间：

1. 当前参数融合主要基于线性近似，后续可探索更灵活的非线性融合机制；
2. 多步融合策略在极低算力设备上的超参敏感性仍需进一步分析；

3. 现阶段实验以视觉单模态为主，尚未系统扩展至图文联合或时序多模态任务。

未来工作将重点围绕以下方向展开：

1. 面向多模态表征学习扩展扩散去噪增强框架；
2. 引入自适应噪声调度与动态融合策略，提升不同场景下的自适应能力；
3. 面向真实部署场景建立更完整的鲁棒评测基准，进一步验证方法的工程可用性。

总体而言，本文工作为扩散模型在判别任务中的高效应用提供了可复用的研究范式，并为复杂场景下高可靠视觉感知系统的构建提供了方法基础。

参考文献

[1] Fang W, Yang S, Yao X. A survey on problem models and solution approaches to rescheduling in railway networks [J]. Intelligent Transportation Systems, IEEE Transactions on, 2015, 16 (6): 2997–3016.

[2] Matsumura T, Tamura S. Cutting Force Model in Milling with Cutter Runout [J]. Procedia CIRP, 2017, 58: 566 – 571. 16th CIRP Conference on Modelling of Machining Operations (16th CIRP CMMO).

附录 A

附录标题

[内容为五号宋体。] 附录是作为论文主体的补充项目，并不是必须的。论文的附录依序用大写正体英文字母 A、B、C……编序号，如：附录 A。

索引

[内容为五号宋体。] 按照需要编排分类索引、著者索引、关键词索引等。

作者简历及攻读硕士学位期间取得的研究成果

一、作者简历

2009 年，毕业于 XX 大学，XX 学院，XX 专业，获 XX 学士；

2009 年至 2010 年，就读于 XX 大学，XX 学院，XX 专业，导师 XX 教授；

2010 年至今，于 XX 大学，XX 实验室，XX 专业攻读博士学位，导师 XX 教授。

二、发表论文

[1] XXX, Truncated adaptation design for decentralized neural dynamic surface control of interconnected nonlinear systems under input saturation, *International Journal of Control*, Volume 89, Issue 7, pp: 1447-1466, 2016. (SCI)

[2] XXX, Lei Chen, Neural adaptive coordination control of multiple trains under bidirectional communication topology, *Neural Computing and Applications*, Volume 27, Issue 8, pp: 2497-2507, 2016. (SCI)

[3] XXX, Neural adaptive control for uncertain MIMO systems with constrained input via intercepted adaptation and single learning parameter approach, *Nonlinear Dynamics*, Volume 82, Issue 3, pp: 1109-1126, 2015. (SCI)

三、参与科研项目

[1]

[2]

[3]

四、专利

[1]

[2]

[3]

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名： 签字日期： 年 月 日

学位论文数据集

表 1.1 数据集页

<table>
<tr><td>关键词 *</td><td>密级 *</td><td>中图分类号</td><td>UDC</td><td>论文资助</td></tr>
<tr><td></td><td></td><td></td><td></td><td></td></tr>
<tr><td colspan="2">学位授予单位名称 *</td><td>学位授予单位代码 *</td><td>学位类别 *</td><td>学位级别 *</td></tr>
<tr><td colspan="2">北京交通大学</td><td>10004</td><td></td><td></td></tr>
<tr><td colspan="2">论文题名 *</td><td colspan="2">并列题名</td><td>论文语种 *</td></tr>
<tr><td colspan="2"></td><td colspan="2"></td><td></td></tr>
<tr><td>作者姓名 *</td><td colspan="2"></td><td>学号 *</td><td></td></tr>
<tr><td colspan="2">培养单位名称 *</td><td>培养单位代码 *</td><td>培养单位地址</td><td>邮编</td></tr>
<tr><td colspan="2">北京交通大学</td><td>10004</td><td>北京市海淀区西直门外上园村 3 号</td><td>100044</td></tr>
<tr><td colspan="2">学科专业 *</td><td>研究方向 *</td><td>学制 *</td><td>学位授予年 *</td></tr>
<tr><td colspan="2"></td><td></td><td></td><td></td></tr>
<tr><td>论文提交日期 *</td><td colspan="4"></td></tr>
<tr><td>导师姓名 *</td><td colspan="2"></td><td>职称 *</td><td></td></tr>
<tr><td>评阅人</td><td colspan="2">答辩委员会主席</td><td colspan="2">答辩委员会成员</td></tr>
<tr><td></td><td colspan="2"></td><td colspan="2"></td></tr>
<tr><td colspan="5">电子版论文提交格式 文本 () 图像 () 视频 () 音频 () 多媒体 () 其他 ()
推荐格式：application/msword; application/pdf</td></tr>
<tr><td colspan="2">电子版论文出版（发布）者</td><td colspan="2">电子版论文出版（发布）地</td><td>权限声明</td></tr>
<tr><td colspan="2"></td><td colspan="2"></td><td></td></tr>
<tr><td>论文总页数 *</td><td colspan="4"></td></tr>
<tr><td colspan="5">共 33 项，其中带 * 为必填数据，为 21 项。</td></tr>
</table>