北京交通大學

硕 士 学 位 论 文

基于扩散模型的图像判别任务特征增强算法研究

Research on Feature Enhancement for Image Discriminative Tasks Based on Diffusion Models

作者：许铮睿

导师：黄晓雯

北京交通大学

2026 年 3 月

学位论文版权使用授权书

本学位论文作者完全了解北京交通大学有关保留、使用学位论文的规定。特授权北京交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：　　导师签名：

签字日期：　　年　　月　　日　　签字日期：　　年　　月　　日

学校代码: 10004 密级: 公开

北京交通大学

硕士学位论文

基于扩散模型的图像判别任务特征增强算法研究

Research on Feature Enhancement for Image Discriminative Tasks Based on Diffusion Models

作者姓名: 许铮睿 学 号: 23120435

导师姓名: 黄晓雯 职 称: 副教授

学位类别: 工学 学位级别: 硕士

学科专业: 计算机科学与技术 研究方向: 模式识别与计算机视觉

北京交通大学

2026 年 3 月

致谢

放置在摘要页前，对象包括：1）国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人。2）协助完成研究工作和提供便利条件的组织或个人。3）在研究工作中提出建议和提供帮助的人。4）给予转载和引用权的资料、图片、文献、研究思想和设想的所有者。5）其他应感谢的组织和个人。

摘要

扩散模型作为一类强大的生成式框架，通过逐步添加高斯噪声并训练去噪网络实现反向预测，已在图像生成、音频合成等领域展现出卓越的性能。然而，扩散模型在判别式任务中的潜力尚未得到充分挖掘。表征学习作为判别式视觉任务的核心环节，旨在学习具有高判别性的数据特征表示，以服务于图像分类、目标检测和图像分割等下游任务。目前，已有少数研究尝试将扩散机制引入特定的判别式场景，但这些方法通常针对单一任务进行定制化设计，缺乏通用性。此外，在推理阶段引入递归式的去噪操作会带来显著的额外计算开销。因此，如何将扩散模型的去噪能力以通用、高效的方式融入判别式表征学习，在不增加推理成本的前提下提升特征的判别性，成为一个亟待解决的关键问题。

本文围绕基于扩散模型的图像判别任务特征增强算法展开系统研究，研究内容和主要贡献如下：

（1）面向无额外推理成本的特征增强算法研究。本文创新性地将骨干网络中每个嵌入层重新解释为去噪层，将级联的 N 个嵌入层类比为扩散模型中 T 步递归去噪过程，在统一框架下实现特征提取与特征去噪的联合建模。在此基础上，通过严格的数学推导提出参数融合策略，证明去噪层参数可等价地合并至原始嵌入层中，使推理阶段的特征去噪无需任何额外计算开销。该方法无需标签信息即可提升特征质量，同时在有标签时亦可作为互补机制进一步增强性能。在行人重识别、图像分类、目标检测和图像分割等多项视觉任务上的实验结果表明，该方法能够稳定且显著地提升各类基线模型的性能。

（2）基于模型蒸馏的特征增强算法研究。针对轻量化去噪模块表达能力受限以及有限去噪深度下效果不足的问题，本文进一步提出两项增强策略。一方面，引入教师—学生蒸馏框架，利用高容量的教师网络为轻量化的学生去噪模块提供更精确的噪声分布估计指导，有效校准去噪方向并降低预测偏差，且该额外开销仅存在于训练阶段。另一方面，提出多步去噪融合策略，包含多轮单层去噪与基于渐进蒸馏的多步融合两种互补机制，通过数学推导将多步迭代过程折叠为等效的单步线性运算，在有限层数下显著增强去噪能力。两项策略分别从噪声预测精度与等效去噪幅度两个维度互补增强，共同实现了更优的特征判别性。大量实验验证了所提方法在多种骨干架构上的有效性与泛化能力，且始终保持推理阶段零额外计算开销的核心优势。

关键词：扩散模型；表征学习；特征去噪；参数融合；知识蒸馏

ABSTRACT

Diffusion models, as a class of powerful generative frameworks, have demonstrated outstanding performance in fields such as image synthesis and audio generation by progressively adding Gaussian noise and training denoising networks for reverse prediction. However, the potential of diffusion models in discriminative tasks remains largely underexplored. Representation learning, as the core component of discriminative visual tasks, aims to learn highly discriminative feature representations for downstream applications including image classification, object detection, and image segmentation. Currently, a few studies have attempted to introduce diffusion mechanisms into specific discriminative scenarios, but these methods are typically tailored to individual tasks and lack generality. Moreover, incorporating recursive denoising operations during inference introduces significant additional computational overhead. Therefore, how to integrate the denoising capability of diffusion models into discriminative representation learning in a general and efficient manner, enhancing feature discriminability without increasing inference cost, remains a critical open problem.

This thesis conducts a systematic study on feature enhancement algorithms for image discriminative tasks based on diffusion models. The main contributions are as follows:

(1) Research on computation-free feature enhancement algorithms. This work innovatively reinterprets each embedding layer in the backbone network as a denoising layer, drawing an analogy between the N cascaded embedding layers and the T-step recursive denoising process in diffusion models, achieving unified modeling of feature extraction and feature denoising within a single framework. Building upon this, a parameter fusion strategy is derived through rigorous mathematical proof, demonstrating that the denoising layer parameters can be equivalently merged into the original embedding layers, enabling zero additional computational overhead for feature denoising during inference. This method operates in a label-free manner to improve feature quality, while also serving as a complementary mechanism to further enhance performance when labels are available. Experimental results on multiple visual tasks, including person re-identification, image classification, object detection, and image segmentation, demonstrate that the proposed method can stably and significantly improve the performance of various baseline models.

(2) Research on distillation-based feature enhancement algorithms. To address the

limited expressiveness of lightweight denoising modules and the insufficient denoising effectiveness under constrained depth, two synergistic enhancement strategies are further proposed. On one hand, a teacher–student distillation framework is introduced, leveraging a high-capacity teacher network to provide more accurate noise distribution estimation guidance for the lightweight student denoising module, effectively calibrating the denoising direction and reducing prediction bias, with the additional overhead incurred only during training. On the other hand, a multi-step denoising fusion strategy is proposed, comprising multi-round single-layer denoising and progressive distillation-based multi-step fusion as two complementary mechanisms, which mathematically collapse multi-step iterative processes into equivalent single-step linear operations, significantly enhancing denoising capability under limited layers. The two strategies complement each other from the perspectives of noise prediction accuracy and effective denoising amplitude, jointly achieving superior feature discriminability. Extensive experiments validate the effectiveness and generalization ability of the proposed methods across multiple backbone architectures, while consistently maintaining the core advantage of zero additional computational overhead during inference.

KEYWORDS: Diffusion Model; Representation Learning; Feature Denoising; Parameter Fusion; Knowledge Distillation

目录

摘要 iii
ABSTRACT iv
1 引言 1
1.1 研究背景与意义 1
1.2 研究现状与挑战 2
1.3 研究内容与主要贡献 4
1.4 论文结构安排 5
2 相关工作 7
2.1 生成式扩散模型 7
2.2 判别式表征学习 8
2.3 扩散模型在判别任务中的应用 10
2.4 高效扩散采样方法 11
2.5 知识蒸馏相关方法 12
2.6 本章小结 13
3 面向无额外推理成本的特征增强算法研究 14
3.1 研究问题与整体框架设计 14
3.2 联合特征提取与特征去噪 15
3.2.1 扩散过程建模 16
3.2.2 去噪网络训练 16
3.3 特征提取与去噪的参数融合 17
3.3.1 双分支结构设计 18
3.3.2 参数融合数学推导 18
3.4 本章实验设计 20
3.4.1 实验设置与评价指标 20
3.4.2 实现细节与训练策略 21
3.5 实验结果与分析 21
3.5.1 基础效果与对比分析 21
3.5.2 效率与开销验证 24
3.6 本章小结 25

4 基于模型蒸馏的特征增强算法研究 26
4.1 从参数融合到蒸馏增强的问题演进 26
4.2 教师--学生蒸馏去噪框架 27
4.2.1 问题分析 27
4.2.2 蒸馏框架设计 28
4.3 有限去噪深度下的增强策略 29
4.3.1 多轮单层去噪 30
4.3.2 多步去噪融合 30
4.4 无监督与有监督学习范式 31
4.5 本章实验设计 33
4.5.1 消融实验设计 33
4.5.2 跨任务实验设置 33
4.6 实验结果与分析 34
4.6.1 消融实验与模块贡献分析 34
4.6.2 跨任务泛化分析 35
4.7 本章小结 39
5 结论与展望 41
5.1 全文工作总结 41
5.2 主要创新点 42
5.3 不足与未来工作 42
参考文献 44
附录 A 51
索引 52
作者简历及攻读硕士学位期间取得的研究成果 53
独创性声明 54
学位论文数据集 55

1 引言

1.1 研究背景与意义

随着计算机视觉技术的快速发展，图像判别式任务已成为人工智能领域中最活跃的研究方向之一。判别式任务涵盖图像分类[1–3]、目标检测[4–6]、图像分割[7,8]以及图像检索[9,10]等广泛的应用场景，其核心目标在于从输入图像中学习有效的特征表示，进而完成对数据的精准预测与理解。在智能交通、公共安全、医疗影像和自动驾驶等实际应用中，判别式视觉模型的性能直接决定了系统的可靠性与可用性，因此受到了学术界和工业界的广泛关注。

表征学习是判别式视觉任务的核心基础，其被定义为“学习数据的表示（或特征），使得在构建分类器或其他预测器时能够更容易地提取有用信息”[11]。一个典型的判别式视觉框架通常由负责特征提取的视觉骨干网络（如 ResNet[12]、ViT[13]）和面向特定任务的预测头（如用于分类的 MLP[14]、用于检测的 RCNN[4]、用于分割的 FCN[7]）组成。其中，骨干网络的特征表达能力对最终的任务性能起着决定性作用。

近年来，深度学习技术的持续演进推动了判别式表征学习取得了显著进步。从早期的卷积神经网络（CNN）[14,15]到残差网络 ResNet[12]，再到基于自注意力机制的 Vision Transformer（ViT）[13,16]和具有层级结构的 Swin Transformer[17]，以及最新兴起的状态空间模型 VMamba[18]，骨干网络的表达能力不断增强，在图像分类[19]、行人重识别[20,21]、目标检测[5,22]和图像分割[7,23]等任务上持续刷新性能记录。然而，尽管这些架构在模型容量和结构设计上取得了重大突破，特征中残留的噪声仍然是制约模型性能进一步提升的重要瓶颈。在推理阶段，噪声可能来源于多个方面：既包括输入图像本身携带的噪声（如光照变化、遮挡、背景杂乱等），也包括特征在网络逐层传播过程中累积的表示噪声。这些噪声导致类内特征分布发散、类间特征边界模糊，从而降低特征的判别性。

在此背景下，扩散模型（Diffusion Model）的兴起为上述问题提供了全新的思路。扩散模型[24]的核心思想是通过向数据持续添加高斯噪声模拟前向扩散过程，再训练去噪网络学习反向去噪过程以恢复原始数据分布。自去噪扩散概率模型（DDPM）[25]提出以来，扩散模型在图像生成[26,27]、视频生成[28]和分子生成[29]等领域均展现出卓越的生成能力，充分表明其具备优良的分布建模能力和强大的噪声抑制能力[30]。这启发研究者思考：能否将扩散模型经过充分验证的去噪能力从生成式任务迁移至判别式任务，用于增强特征表示的质量？

综上所述，如何设计一种通用的特征增强范式，有效利用扩散模型的去噪能力来提升判别式表征的质量，同时避免推理阶段的额外计算开销，具有重要的理论意义和实际应用价值。一方面，从理论角度而言，探索生成式扩散模型与判别式表征学习的统一建模，有望为理解两类学习范式之间的内在联系提供新的视角，推动深度学习理论的发展。另一方面，从应用角度而言，设计零额外推理开销的特征去噪方法，能够在不改变已有模型部署架构的前提下增量式地提升各类视觉任务的性能，为实际工程系统提供即插即用的特征增强工具，具有广泛的应用前景。

1.2 研究现状与挑战

生成式模型旨在学习数据的底层分布 $P(X)$ 或联合分布 $P(X,Y)$，进而合成符合该分布的新样本。经典的生成式模型包括生成对抗网络（GAN）[31–33] 和变分自编码器（VAE）[34–36] 等，它们通过学习隐空间表示捕获数据的生成过程，在图像合成、风格迁移等任务中取得了显著进展。近年来，扩散模型作为一类新兴的生成式框架引起了广泛关注。Sohl-Dickstein 等人[24] 于 2015 年最早提出扩散概率模型的基本框架，通过迭代去除训练图像中的高斯噪声来建模数据分布。2020 年，Ho 等人[25] 提出去噪扩散概率模型（DDPM），通过精心设计的噪声调度策略和简化的训练目标，使扩散模型在图像生成质量上首次超越 GAN，成为生成式建模的主流方法。此后，扩散模型在多种生成任务中持续展现出卓越能力：Stable Diffusion[26] 通过在隐空间进行扩散过程实现了高分辨率图像合成，DALL • E[27] 系列实现了零样本文本到图像生成，Imagen[37] 通过结合深度语言理解实现了逼真的图像生成。此外，扩散模型还被拓展至视频生成[28] 和分子生成[29] 等领域。在推理加速方面，DDIM[38] 提出非马尔可夫扩散过程以减少采样步数，渐进式蒸馏[39] 和 DPM-Solver[40] 等方法进一步提升了采样效率。这些成果充分表明，扩散模型具备优良的数据分布建模能力和强大的噪声抑制能力[30]。

尽管扩散模型在生成领域取得了巨大成功，但其在判别式任务中的探索仍然相对有限。与生成式模型通过建模联合分布 $P(X,Y)$ 来合成样本不同，判别式模型关注的是条件分布 $P(Y|X)$ 的估计，其中 Y 可以是分类标签、检测框或分割掩码等任务特定输出。近年来，一些研究开始尝试将扩散机制引入特定的判别式任务。DiffusionDet[41] 将目标检测建模为从噪声框到目标框的去噪扩散过程，通过在检测框空间施加前向扩散并训练去噪网络逐步恢复精确的目标框坐标，在与成熟检测器的比较中取得了具有竞争力的表现。DiffSeg[42] 利用预训练的稳定扩散模型实现了无监督零样本图像分割，通过迭代合并基于 KL 散度的注意力图生成有效的分割掩码，无需额外训练或文本监督即可获得良好的分割效果。此外，CLIP-Diffusion[43] 等工作探索了结合预训练视觉-语言模型与扩散机制的零样本学习方案。然而，上

述方法均存在两方面的共同局限：其一，方法针对特定任务进行定制化设计，依赖于特定的数据结构（如 DiffusionDet 操作的是噪声边界框，DiffSeg 操作的是噪声初始化的分割图），难以直接迁移至其他判别式任务，缺乏通用性；其二，递归式的去噪推理过程需要多步迭代采样，引入了显著的额外计算开销，限制了实际部署中的推理效率。

与此同时，特征噪声问题广泛存在于各类判别式视觉任务之中，是制约模型性能进一步提升的共性瓶颈。在图像分类任务中[14,19]，尤其是细粒度分类场景[44–46]下，类间视觉差异细微，特征中的噪声容易导致类间特征边界模糊，显著影响分类精度。在目标检测任务中[4,5,22]，背景杂乱、目标遮挡和尺度变化等因素引入的噪声会干扰区域特征的判别性，降低检测准确率。在图像分割任务中[7,8,23]，像素级预测要求特征具有精细的空间对应关系，特征噪声容易导致分割边界不精确和小目标区域的错误预测。在图像检索任务中[9,20,21]，以行人重识别为代表的细粒度检索需要跨摄像头匹配同一目标，面临姿态变化、光照差异、遮挡干扰等严峻挑战[47–49]，对特征的身份判别性和鲁棒性要求极高。现有方法主要通过改进网络架构[12,13,17]、设计注意力机制[16] 或引入数据增强策略来缓解噪声影响，但尚缺乏一种从特征表示层面直接进行去噪增强的通用范式。

此外，知识蒸馏[50] 作为一种通过教师-学生架构进行模型压缩和知识传递的训练范式，近年来得到了广泛应用。在该框架中，参数量较大、表达能力较强的教师模型为轻量化的学生模型提供软监督信号，使学生模型在保持高效的同时获得接近教师模型的性能。在扩散模型的语境下，知识蒸馏同样发挥着重要作用：渐进式蒸馏[39] 通过将多步采样过程压缩为更少的步数来加速扩散模型推理。这启发了一个重要思路——当去噪模块由于参数融合的需要被设计为轻量化结构时，可以借助更具表达能力的教师网络在训练阶段提供更精确的噪声分布估计，通过蒸馏将教师的去噪知识传递给轻量化的学生模块，从而在不增加推理开销的前提下提升去噪质量。上述各方面的研究现状将在第二章进行更为详尽的综述。

综合以上分析，当前将扩散模型的去噪能力应用于判别式表征学习面临以下三方面的关键挑战：

挑战一：缺乏通用的特征去噪框架。现有的扩散式判别方法均针对特定任务的特定数据结构设计去噪过程，无法通用地增强骨干网络提取的特征表示。亟需一种与任务无关的通用特征去噪范式，使生成式去噪能力能够无缝嵌入各类判别式框架之中。

挑战二：去噪过程引入不可忽视的推理开销。标准扩散模型的去噪过程采用递归式多步迭代，每一步都需要完整的网络前向计算，这在推理阶段引入了显著的额外计算开销。对于实时性要求严格的实际部署场景（如自动驾驶、视频监控），

这种开销通常是不可接受的。如何实现去噪增强与推理零开销的兼顾，是一个核心技术难题。

挑战三：轻量化去噪模块的能力瓶颈。若为了实现推理零额外开销而将去噪模块设计为轻量化结构以便与骨干网络参数融合，则其有限的参数量会制约对复杂高维噪声分布的建模能力，导致去噪效果受限。如何在保持参数可融合性的同时提升去噪模块的有效去噪能力，需要新的训练策略和架构设计。

1.3 研究内容与主要贡献

针对上述挑战，本文以‘‘基于扩散模型的图像判别任务特征增强’’为核心研究主题，提出了两种互补的特征增强算法，系统性地探索了生成式去噪能力在判别式表征学习中的有效利用。

研究内容一：面向无额外推理成本的特征增强算法（第三章）。针对挑战一和挑战二，本文提出了一种将扩散模型的去噪过程融入判别式骨干网络的通用特征增强方法。该方法的核心思想是：将骨干网络中级联的 N 个嵌入层（如卷积层或多头注意力层）重新解释为 T 步递归去噪层，使得特征提取与特征去噪在网络的逐层传播中同步完成。在此基础上，本文设计了一种参数融合机制，将训练好的去噪模块的参数直接合并至对应的嵌入层参数中，并从理论上证明了融合前后的数学等价性，从而在推理阶段完全消除了去噪过程带来的额外计算开销。该方法作为一种无标签增量式特征增强算法，可以即插即用地应用于各种预训练骨干网络和下游判别任务。

研究内容二：基于模型蒸馏的特征增强算法（第四章）。针对挑战三，本文在上述基础框架之上提出两个协同增强模块。第一，针对轻量化去噪模块建模能力不足的问题，引入教师-学生蒸馏框架：在训练阶段使用一个表达能力更强的教师网络来指导轻量化的学生去噪模块，教师网络提供更丰富、更具判别性的噪声分布估计，帮助学生模块更准确地捕捉结构化噪声模式，提升去噪方向的校准精度。第二，针对有限去噪深度下单步去噪存在的离散化误差问题，提出多步去噪融合策略：包括多轮单层去噪（将单个去噪层的多步迭代通过递推公式折叠为一次线性运算）和多步去噪蒸馏（借鉴 DDIM[38] 式跳步采样思想，将教师的多步去噪轨迹蒸馏至学生的单步去噪中）。上述增强模块仅在训练阶段引入额外计算，推理阶段仍然保持零额外开销的特性。

本文的主要贡献总结如下：

（1）提出了一种通用的基于扩散去噪的判别式特征增强框架，将骨干网络的 N 个级联嵌入层重新解释为 T 步递归去噪步骤，实现了特征提取与特征去噪的同步进行，生成更具判别性的特征表示。

（2）设计了特征提取与去噪参数融合策略，将去噪模块参数合并入嵌入层参数中，并从理论上证明了融合前后的数学等价性，实现了推理阶段零额外计算开销的特征增强。

（3）引入教师-学生蒸馏框架指导轻量化去噪模块的训练，通过更具表达能力的教师网络提供精确的噪声分布估计，在不增加推理开销的前提下显著提升了去噪模块的去噪能力。

（4）提出了多轮单层去噪与多步去噪融合两种增强策略，将多步去噪轨迹压缩为等效的单步操作，在有限去噪深度下增强了去噪性能和特征可分性。

（5）在行人重识别（Market-1501、DukeMTMC-reID、MSMT17、CUHK-03、VehicleID）、图像分类（ImageNet、CUB200、Oxford-Pet、Flowers）、目标检测（COCO）和图像分割（ADE20K）等多类视觉判别任务上进行了广泛实验，验证了所提方法在 CNN 架构（ResNet）和 Transformer 架构（ViT、Swin、VMamba）上的一致性能提升。

1.4 论文结构安排

本文围绕‘‘基于扩散模型的图像判别任务特征增强算法研究’’这一主题，从理论分析、算法设计到实验验证逐步展开，共分为五章。各章内容安排如下：

第一章为绪论。

首先介绍图像判别式任务与表征学习的研究背景，阐述扩散模型在特征增强方面的应用意义；随后综述扩散模型、判别式表征学习和知识蒸馏等领域的研究现状，分析当前面临的三个关键挑战；在此基础上明确本文的两项研究内容并总结主要贡献；最后概述论文的整体组织结构。

第二章为相关工作。

系统综述与本文研究密切相关的基础理论与技术方法。具体包括：生成式扩散模型的基本原理、前向扩散与反向去噪的数学框架及其发展历程；卷积神经网络、Vision Transformer 等判别式表征学习的代表性骨干网络及其演进脉络；扩散模型在目标检测、图像分割等判别任务中的已有探索及其局限性；DDIM、渐进式蒸馏、DPM-Solver 等高效扩散采样方法；以及教师-学生知识蒸馏的基本范式与典型应用。本章为后续两章的方法设计提供理论基础与技术参照。

第三章为面向无额外推理成本的特征增强算法研究。

针对缺乏通用特征去噪框架和去噪推理开销两大挑战，本章提出将骨干网络中级联的嵌入层重新解释为递归去噪层的统一框架，实现特征提取与特征去噪的同步进行。在此基础上，设计参数融合机制将去噪模块参数合并入嵌入层参数中，并从理论上严格证明融合前后的数学等价性，从而在推理阶段完全消除额外计算开销。

本章还详细介绍了实验设置与评价指标，并通过在行人重识别、图像分类、目标检测和图像分割等多类判别式任务上的对比实验，全面验证了所提方法的有效性、通用性和效率优势。

第四章为基于模型蒸馏的特征增强算法研究。

针对第三章中轻量化去噪模块因参数量有限而导致建模能力受限的问题，本章首先分析从参数融合到蒸馏增强的问题演进逻辑，随后提出两个协同增强模块：一是引入教师-学生蒸馏框架，利用高容量教师网络在训练阶段指导轻量化学生去噪模块，提升噪声分布估计的精度；二是提出多步去噪融合策略，包括多轮单层去噪和多步去噪蒸馏两种具体方案，在有限去噪深度下增强去噪效果。本章通过详尽的消融实验验证各模块的独立贡献与协同效应，并通过跨任务、跨架构的泛化实验进一步确认方法的鲁棒性。

第五章为结论与展望。

总结本文在基于扩散模型的判别式特征增强方面的主要工作与创新点，客观分析现有方法在适用场景、计算资源和理论深度等方面的局限性，并对跨模态特征去噪、自适应去噪调度以及与大规模预训练模型结合等未来研究方向进行展望。

2 相关工作

本章系统综述与本文研究密切相关的基础理论与技术方法。首先介绍生成式扩散模型的基本原理与发展历程；随后回顾判别式表征学习中骨干网络的演进脉络；接着综述扩散模型在判别任务中的已有探索；然后讨论高效扩散采样方法；最后介绍知识蒸馏的基本范式与典型应用。

2.1 生成式扩散模型

生成式模型旨在学习数据的底层分布，进而能够合成符合该分布的新样本。典型的生成式模型通过估计每个类别的条件似然 $P(\mathbf{x}|y=k)$ 及先验类别概率 $P(y=k)$，再由全概率公式计算边缘分布 $P(\mathbf{x})$，从而近似各类别数据的概率分布，并通过从学习到的分布中采样来生成新数据。

经典的生成式模型包括生成对抗网络（Generative Adversarial Networks, GANs）[31–33] 和变分自编码器（Variational Autoencoders, VAEs）[34–36,51]。GAN 通过生成器与判别器之间的对抗训练，在隐空间中学习数据的生成过程，能够产生高质量的合成样本。VAE 则通过编码器-解码器结构学习数据的隐变量分布，在图像生成和表示学习中均取得了显著进展。这两类方法在建模数据生成过程方面展现出了优秀的性能。

近年来，研究关注逐步转向扩散模型（Diffusion Models）。扩散模型的基本框架最早由 Sohl-Dickstein 等人[24] 于 2015 年提出，其核心思想是通过迭代去除训练图像中的高斯噪声来建模数据分布。具体而言，扩散模型包含前向扩散和反向去噪两个对称过程。在前向扩散过程中，模型通过马尔可夫链逐步向数据 $\mathbf{x}_0$ 添加高斯噪声，经过 T 步后将原始数据转化为近似的标准高斯分布：

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1-\beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I}) \tag{2.1}$$

其中 β_t 为预先设定的噪声调度参数。在反向去噪过程中，模型训练一个参数化的去噪网络 ε_θ 来逐步恢复原始数据分布：

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t,t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t,t)) \tag{2.2}$$

通过训练去噪网络预测每步添加的噪声 ε，模型能够从纯噪声出发通过迭代去噪生成高质量的样本。

2020 年，Ho 等人[25] 提出去噪扩散概率模型（DDPM），通过精心设计的噪声调度策略和简化的训练目标函数 $\mathscr{L} = \mathbb{E}_{t,\mathbf{x}_0,\varepsilon}[||\varepsilon - \varepsilon_\theta(\mathbf{x}_t,t)||^2]$，使扩散模型在图像生

成质量上首次超越 GAN，确立了扩散模型作为生成式建模主流方法的地位。Nichol 和 Dhariwal[52] 进一步提出改进型 DDPM，通过学习反向过程的方差参数和引入余弦噪声调度策略，在保持样本质量的同时大幅减少了所需的采样步数并提升了对数似然度。Dhariwal 和 Nichol[53] 则通过系统性的架构搜索和分类器引导（Classifier Guidance）策略，首次在条件图像生成任务上使扩散模型在 FID 指标上全面超越 GAN，奠定了扩散模型在视觉生成领域的主导地位。

在理论框架方面，Song 等人[54] 提出基于随机微分方程（SDE）的统一生成建模框架，将 DDPM 和基于分数的生成模型纳入连续时间 SDE 的统一视角。该工作引入了预测器-校正器框架，并推导出等价的常微分方程（ODE）形式以实现精确的似然计算和高效采样，为扩散模型提供了更加系统化的数学基础。

此后，扩散模型在多种生成任务中持续展现出卓越的能力。Stable Diffusion[26] 通过将扩散过程迁移至隐空间（Latent Space）进行，实现了高分辨率图像的高效合成。DALL • E[27] 系列将文本编码器与扩散生成器相结合，实现了零样本文本到图像的生成。Imagen[37] 通过引入大规模语言模型的深度文本理解能力，进一步提升了文本引导图像生成的逼真度。

在网络架构方面，早期扩散模型普遍采用 U-Net 作为去噪骨干网络。Peebles 和 Xie[55] 提出了扩散 Transformer（DiT），首次以 Transformer 架构替代 U-Net 作为隐空间扩散模型的骨干网络。DiT 通过在隐空间图像块上操作，并利用自适应层归一化（AdaLN）注入条件信息，展现出优异的可扩展性——更高的计算量（以 GFLOPs 衡量）持续带来更低的 FID 分数。其最大的 DiT-XL/2 模型在 class-conditional ImageNet 256×256 基准上取得了 2.27 的 FID，刷新了当时的生成质量记录。这一工作深刻影响了后续大规模视觉生成模型的架构设计。

此外，Lipman 等人[56] 提出了流匹配（Flow Matching）方法，为训练连续归一化流（CNF）提供了一种无需模拟的高效范式。流匹配通过回归固定条件概率路径的向量场来训练 CNF，兼容包括扩散路径在内的多种高斯概率路径族，并发现使用最优传输位移插值定义的路径相比扩散路径具有更高的训练与采样效率。扩散模型还被成功拓展至视频生成[28]、分子结构生成[29] 和离散数据建模[57] 等领域。

除了强大的生成能力，扩散模型还具备内禀的去噪能力——通过迭代的噪声估计与去除过程，能够从含噪观测中有效恢复原始数据分布[30]。这一特性为将扩散模型的去噪机制迁移至判别式任务提供了理论基础。

2.2 判别式表征学习

与生成式模型关注数据分布 $P(\mathbf{x})$ 或联合分布 $P(\mathbf{x}, y)$ 的建模不同，判别式模型专注于学习条件概率分布 $P(y|\mathbf{x})$，其中 $\mathbf{x}$ 表示输入数据，y 表示任务特定的输出或

标签。根据任务类型的不同，判别式模型涵盖了广泛的应用：分类模型[1–3]将输入映射为离散的类别标签；检索模型[9,10]学习特征空间使语义相似的样本在特征空间中彼此靠近；检测模型[4,58]则通过预测空间位置和边界框来定位和分类目标。

表征学习是各类判别式任务的核心基础，其目标是学习数据的有效表示以便于下游任务的信息提取[11]。在视觉表征学习领域，骨干网络的架构设计经历了数次重要的范式变革。

卷积神经网络（CNN）是深度视觉表征学习的奠基架构。LeNet[15]首次将卷积运算应用于图像识别，奠定了 CNN 的基本结构。AlexNet[14]在 2012 年 ImageNet[19]大规模视觉识别挑战赛上取得了突破性成绩，标志着深度学习时代的开启。此后，一系列精心设计的 CNN 架构不断推动性能的提升。ResNet[12]通过引入残差连接解决了深层网络的梯度消失问题，使训练数百层深度的网络成为可能。RegNet[59]通过系统性的网络设计空间搜索，提出了一组参数化的网络设计准则。EfficientNet[60]通过复合缩放策略同时优化网络的深度、宽度和分辨率，在多个基准上实现了精度与效率的良好平衡。值得注意的是，在 Transformer 架构主导视觉领域之后，Liu 等人[61]提出了 ConvNeXt，通过系统性地将现代设计元素（如大卷积核、层归一化、GELU 激活等）引入标准卷积网络，在 ImageNet 分类上达到 87.8% 的 top-1 精度，并在 COCO 检测和 ADE20K 分割任务上超越了 Swin Transformer，证明了纯卷积架构仍然具有与 Transformer 相当的竞争力。

自注意力机制的引入开启了视觉表征学习的新范式。Transformer 架构最初由 Vaswani 等人[16]为自然语言处理领域提出，其核心的多头自注意力机制能够捕捉输入序列中任意位置之间的长程依赖关系。Dosovitskiy 等人[13]将 Transformer 直接应用于图像分类，提出了 Vision Transformer（ViT），将图像划分为一系列固定大小的图像块（Patch），并将每个图像块视为一个词元（Token）进行处理。ViT 在大规模数据集上取得了与 CNN 相当甚至更优的性能，证明了 Transformer 架构在视觉任务中的强大潜力。DeiT[62]通过精心设计的知识蒸馏策略和数据增强方案，使 ViT 在中等规模数据集上也能高效训练。Swin Transformer[17]引入了层级结构和移位窗口注意力机制，在保持线性计算复杂度的同时实现了跨窗口信息交互，成为多种视觉任务的通用骨干网络。

在自监督表征学习方面，近年来涌现了一系列重要工作。He 等人[63]提出了掩码自编码器（MAE），通过随机掩盖 75% 的图像块并重建缺失像素来进行自监督预训练。MAE 采用非对称的编码器-解码器架构，其中编码器仅处理可见的图像块子集，从而实现了高效的大规模模型训练。在 ImageNet-1K 上，ViT-Huge 模型通过 MAE 预训练达到了 87.8% 的 top-1 精度，同时在下游任务上展现出优异的迁移性能。Oquab 等人[64]提出的 DINOv2 进一步推进了自监督视觉基础模型的发

展——通过在经过自动筛选的大规模多源图像数据上训练 ViT 模型（参数量达 10 亿），并结合自蒸馏策略将知识迁移至一系列小型模型，DINOv2 能够产生在不同图像分布和任务间具有强泛化能力的通用视觉特征，在图像级和像素级的多个基准上超越了此前的最优方法。

最近，基于状态空间模型的 VMamba[18] 引入了选择性扫描机制，能够以线性复杂度建模长序列依赖关系，在图像分类、目标检测和语义分割等任务上展现出与 Transformer 架构相当的性能，同时具备更高的计算效率。

在具体的判别式任务中，行人重识别（Person Re-Identification, ReID）[20,21] 是一个对特征判别性要求极高的代表性任务。ReID 旨在跨不相交摄像头视角匹配同一行人的图像，面临姿态变化、光照差异和遮挡等严峻挑战。ReID 方法的发展主要经历了两个阶段：早期方法依赖手工设计的描述子[47,65,66] 结合度量学习[67–69]；现代方法则以基于深度学习的端到端框架为主[48,49,70–73]。当前的 ReID 系统普遍采用 CNN[15] 或 Transformer[13,16] 作为骨干网络建模复杂的空间关系与层级化视觉表示，并通过注意力机制[13,16]、时空推理[74,75] 和域适应方法[76] 进一步增强模型在实际部署场景中的鲁棒性和泛化能力。此外，RepVGG[77] 提出的结构重参数化思想——在训练阶段使用多分支拓扑以增强表达能力，在推理阶段将多分支融合为单一卷积以保持高效——为本文的参数融合策略提供了重要的技术启发。

2.3 扩散模型在判别任务中的应用

尽管扩散模型在生成任务中取得了巨大成功，其在判别式任务中的探索仍处于起步阶段。近年来，一些研究开始尝试将扩散机制引入特定的判别式任务框架中。

在目标检测领域，DiffusionDet[41] 首次将目标检测建模为从噪声边界框到精确目标框的去噪扩散过程。该方法在训练阶段对真实目标框施加前向扩散以生成噪声框作为训练样本，在推理阶段则从随机生成的噪声框出发，通过迭代去噪逐步恢复精确的目标框坐标。DiffusionDet 在与 Faster R-CNN[4] 等成熟检测器的比较中取得了具有竞争力的表现，展示了扩散范式在检测任务中的可行性。

在图像分割领域，DiffSeg[42] 利用预训练的稳定扩散模型实现了无监督零样本图像分割。该方法提出了一种迭代注意力合并机制，通过聚合基于 KL 散度的自注意力图来生成有效的分割掩码，无需额外训练数据或文本监督信号即可获得良好的分割效果。此外，Baranchuk 等人[78] 从另一个角度验证了扩散模型在分割任务中的潜力——他们发现，预训练扩散模型在反向去噪过程中的中间层激活能够有效捕捉输入图像的语义信息，构成优质的像素级表征。基于此发现，他们提出了一种简洁的少样本分割方法，仅需少量标注图像即可在多个数据集上显著超越已

有的替代方案。这一工作从实证角度表明，扩散模型内部的去噪特征天然蕴含了丰富的判别性语义信息。

在零样本分类领域，Li 等人[79] 提出了扩散分类器（Diffusion Classifier）的概念，证明了大规模文本到图像扩散模型（如 Stable Diffusion）的条件密度估计可以直接用于执行零样本分类，无需任何额外训练。该方法通过比较不同类别文本提示下扩散模型对输入图像的条件似然来进行分类决策，在多种基准上取得了优异的结果，且在多模态组合推理能力上显著优于现有的判别式方法。在零样本学习领域，CLIP-Diffusion[43] 探索了将预训练的视觉-语言模型 CLIP 与扩散机制相结合的方案，利用扩散过程增强视觉特征与文本描述之间的对齐，在零样本分类和检索任务中取得了改进。

然而，上述方法均存在共同的局限性。首先，这些方法针对特定任务进行定制化设计，依赖于特定的数据结构——例如 DiffusionDet 操作的是噪声边界框空间，DiffSeg 操作的是噪声初始化的分割图——因此难以直接迁移至其他判别式任务，缺乏通用性。其次，多步递归的去噪推理过程引入了显著的额外计算开销，在实际部署中面临效率瓶颈。这些局限性促使研究者探索更为通用且高效的扩散式特征增强范式。

2.4 高效扩散采样方法

扩散模型面临的核心挑战之一在于推理阶段的高计算成本，因为传统的去噪过程通常需要数百乃至数千步迭代采样才能生成高质量样本。为缓解这一效率瓶颈，近年来涌现了一系列加速采样技术。

DDPM[25] 建立了基本的迭代去噪框架，虽然能够生成高质量样本，但推理时间较长。为提升效率，Song 等人[38] 提出了去噪扩散隐式模型（Denoising Diffusion Implicit Model, DDIM），通过引入确定性的非马尔可夫采样过程重新参数化了反向去噪过程。DDIM 在保持生成质量的前提下，将所需的采样步数从原始 DDPM 的数千步大幅减少至数十步，显著提升了推理效率。

在 DDIM 的基础上，渐进式蒸馏（Progressive Distillation）[39] 提出了一种基于知识蒸馏的采样加速策略。该方法通过训练一个学生模型来匹配教师模型执行两步连续去噪的输出，从而在每一轮蒸馏中将所需采样步数减半。通过多轮迭代蒸馏，可以将长扩散轨迹有效压缩为更少的采样步数，且不显著损失生成质量。这种蒸馏式加速策略为本文第四章中设计的多步去噪蒸馏机制提供了直接的技术启发。

DPM-Solver[40] 从另一个角度解决了高效采样问题。该方法将扩散过程建模为常微分方程（ODE），并采用高阶数值求解器来高效近似去噪轨迹。DPM-Solver 仅需 10 至 20 步采样即可生成高保真度的样本，在采样效率上实现了进一步突破。

Song 等人[80] 提出了一致性模型（Consistency Models），从根本上改变了扩散采样的范式。不同于传统方法通过多步迭代逐步去噪，一致性模型通过学习概率流 ODE 轨迹上任意点到原始数据的直接映射，实现了单步或少步高质量采样。一致性模型既可以通过蒸馏预训练的扩散模型获得，也可以作为独立的生成模型从头训练，在 CIFAR-10 上取得了单步生成 3.55 的 FID，在 ImageNet 64×64 上取得了 6.20 的 FID，均刷新了当时的单步生成记录。Luo 等人[81] 进一步将一致性模型扩展至隐空间，提出了隐空间一致性模型（Latent Consistency Models, LCM），能够在任意预训练的隐空间扩散模型（如 Stable Diffusion）上进行高效蒸馏，仅需 2 至 4 步即可生成高质量的 768×768 分辨率图像，整个训练过程仅需 32 块 A100 GPU 小时。

Liu 等人[82] 提出了矫正流（Rectified Flow），通过学习连接噪声分布与数据分布之间的直线路径，构建了一种简洁高效的 ODE 生成模型。矫正流的核心思想是在两个分布的样本之间学习尽可能直的传输路径——直线路径不仅是两点间的最短路径，而且可以在不进行时间离散化的情况下精确模拟，因此产生了计算效率极高的模型。通过递归地应用矫正操作，可以获得路径越来越直的流模型，使得粗粒度的时间离散化（甚至单步 Euler 离散化）也能产生高质量的生成结果。

上述加速采样技术的发展反映了扩散模型领域在去噪精度与计算效率之间寻求平衡的持续努力。这些工作，特别是基于蒸馏的加速方法和一致性学习范式，为本文在有限计算预算下设计高效的特征去噪增强机制提供了重要的方法论参考。

2.5 知识蒸馏相关方法

知识蒸馏的概念最早由 Hinton 等人[83] 系统性地提出，其核心思想是将一个参数量较大、表达能力较强的教师模型所学到的 ‘‘暗知识"（Dark Knowledge）迁移给一个参数量较小的学生模型。具体而言，教师模型输出的软化概率分布（通过温度系数 τ 调节 softmax 函数）编码了类别之间的相似性关系，这些信息比硬标签更加丰富，能够为学生模型提供更加细粒度的指导。知识蒸馏已在模型压缩、增量学习和跨模态迁移学习等多种场景中得到了广泛应用[50]。

在蒸馏方法的发展过程中，Romero 等人[84] 提出了 FitNets，将知识蒸馏从输出层扩展到中间层特征表示。FitNets 利用教师网络的中间隐层表征作为 ‘‘提示"（Hints）来指导学生网络对应层的训练，并引入适配层来处理教师与学生中间层之间的维度差异。这种基于特征的蒸馏方法使得学生网络可以更深更窄，在 CIFAR-10 上仅用教师约十分之一的参数量即可超越教师网络的性能，开创了特征级知识蒸馏的研究方向。

Tian 等人[85] 从表征学习的角度重新审视了知识蒸馏，提出了对比表征蒸馏

（Contrastive Representation Distillation, CRD）。该方法指出传统的 KL 散度蒸馏损失只关注教师与学生输出分布的匹配，而忽略了教师表征中蕴含的结构化知识。CRD 通过对比学习的方式训练学生模型，使其能够捕获教师表征中更丰富的结构信息——学生特征应当与对应的教师特征在表征空间中彼此靠近，同时远离其他样本的教师特征。CRD 在多种知识迁移场景中均超越了传统蒸馏方法。

在视觉表征学习领域，知识蒸馏被广泛用于训练高效的小型模型。例如，DeiT[62] 通过引入蒸馏令牌（Distillation Token），利用 CNN 教师模型指导 ViT 学生模型的训练，使得 Vision Transformer 在没有大规模预训练数据的条件下也能取得优异性能。在行人重识别任务中，自蒸馏和互蒸馏策略也被用于增强特征的判别性[86]。

在扩散模型的语境下，知识蒸馏同样发挥着重要作用。如前节所述，渐进式蒸馏[39] 通过教师-学生框架将多步采样过程压缩为更少的步数，实现了扩散模型推理的显著加速。一致性模型[80] 亦可通过蒸馏预训练扩散模型来获得单步生成能力。这些工作为本文的研究提供了重要启发：当去噪模块为了实现推理阶段的参数融合而被设计为轻量化结构时，其有限的参数量会制约对复杂高维噪声分布的建模能力。此时，可以借助一个表达能力更强的教师网络在训练阶段提供更精确的噪声分布估计，通过蒸馏将教师的去噪知识传递给轻量化的学生去噪模块，从而在不增加推理开销的前提下提升去噪质量。

2.6 本章小结

本章从五个方面综述了与本文研究密切相关的理论基础与技术方法。在生成式扩散模型方面，回顾了从 GAN、VAE 到扩散模型的发展历程，详细阐述了扩散模型的前向扩散与反向去噪数学框架，以及 DDPM、改进型 DDPM、基于分数的 SDE 等里程碑式工作，并介绍了 DiT 和流匹配等前沿的架构与范式创新。在判别式表征学习方面，梳理了从 CNN 到 Vision Transformer 再到状态空间模型的骨干网络演进脉络，涵盖了 ConvNeXt 等现代卷积架构的回归、MAE 和 DINOv2 等自监督学习方法的突破，以及行人重识别等典型任务中的方法发展。在扩散模型的判别式应用方面，分析了 DiffusionDet、DiffSeg、扩散分类器和扩散特征语义分割等代表性工作的技术方案及其在通用性和效率方面的局限。在高效扩散采样方面，介绍了 DDIM、渐进式蒸馏、DPM-Solver、一致性模型、隐空间一致性模型和矫正流等加速技术，为本文的多步去噪融合策略提供方法论参考。在知识蒸馏方面，从 Hinton 等人的开创性工作出发，阐述了 FitNets 特征级蒸馏和 CRD 对比表征蒸馏等重要方法，以及知识蒸馏在视觉表征学习和扩散模型加速中的应用，为本文的蒸馏增强去噪模块奠定理论基础。上述综述为后续第三章和第四章的方法设计提供了全面的技术参照与理论支撑。

3　面向无额外推理成本的特征增强算法研究

本章针对判别式骨干网络提取的特征中仍残留噪声这一共性问题，提出一种面向无额外推理成本的特征增强算法。该算法的核心思想是将扩散模型的去噪过程与骨干网络的特征提取过程进行统一建模，并通过参数融合机制在推理阶段完全消除去噪操作带来的额外计算开销。本章首先在第3.1节阐述研究问题并给出整体框架设计；随后在第3.2节详细介绍联合特征提取与特征去噪的建模方法；接着在第3.3节推导特征提取与去噪的参数融合算法及其数学等价性证明；第3.4节和第3.5节分别介绍实验设置与实验结果分析；最后在第3.6节对本章工作进行总结。

3.1　研究问题与整体框架设计

如第一章所述，判别式视觉模型通过骨干网络逐层提取特征表示，并在此基础上完成分类、检测、分割和检索等下游任务[11]。然而，在实际推理过程中，骨干网络输出的特征向量中不可避免地包含来自多种来源的噪声：一方面，输入图像本身可能受到光照变化、遮挡、背景杂乱和传感器噪声等因素的干扰；另一方面，特征在网络逐层传播的过程中也会累积表示噪声，导致最终特征的类内分布发散、类间边界模糊，进而影响下游任务的判别精度。

扩散模型[24,25] 作为一类强大的生成式框架，具备经过充分验证的噪声去除能力——通过迭代的噪声估计与去除过程，能够从含噪数据中逐步恢复原始的干净分布[30]。然而，将扩散模型的去噪能力直接应用于判别式任务面临两个核心矛盾：其一，标准扩散模型的去噪过程需要在特征提取完成之后附加一个独立的多步迭代去噪模块，这将引入不可忽视的额外推理延迟；其二，若为每个下游任务单独设计扩散去噪流程（如 DiffusionDet[41] 对检测框去噪、DiffSeg[42] 对分割图去噪），则方法缺乏通用性，难以在不同任务间迁移。

为解决上述矛盾，本章提出了一种将特征提取与特征去噪统一建模的算法框架[87]。其核心思路如图3.1所示，经历了从分离到统一、从额外开销到零开销的四个阶段的演进：

（a）标准去噪过程：去噪层对含噪特征执行 T 步迭代去噪以获得干净特征，这是扩散模型的基本工作模式。

（b）骨干网络末端附加去噪：在判别式骨干网络的 N 个嵌入层完成特征提取之后，在网络末端附加一个独立的去噪模块对输出特征进行 T 步去噪。这种方式虽然能够改善特征质量，但去噪模块作为独立组件引入了额外的推理延迟。

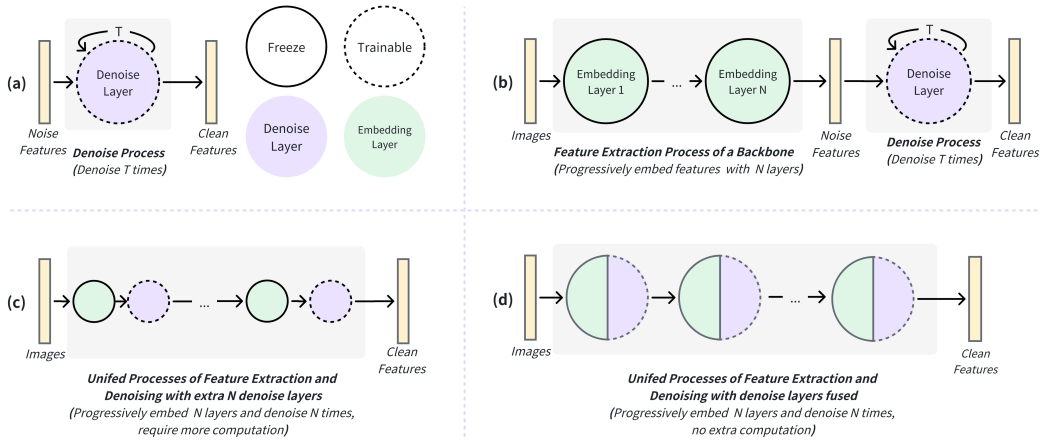

图 3.1　特征去噪与特征提取统一框架的思路演进示意图

Fig. 3.1　Illustration of the idea evolution from separate denoising to unified feature extraction and denoising framework

（c）逐层统一但增加计算：将去噪层嵌入骨干网络的每一个特征提取层，使特征提取与去噪在每一层同步进行。每一层的嵌入操作与去噪操作并行执行，实现了特征提取与去噪的统一。然而，由于每一层新增了独立的去噪分支，总体计算量相应增加。

（d）参数融合实现零额外开销：在方案（c）的基础上，通过数学推导证明去噪层的参数可以与对应嵌入层的参数进行等价融合。融合后的网络结构和参数量与原始骨干网络完全相同，从而在推理阶段实现了特征去噪的零额外计算开销。这是本章算法的最终方案。

基于上述思路，本章所提方法的整体框架可以概括为三个阶段。第一阶段，冻结预训练骨干网络的全部参数，仅训练附加在每一层上的轻量级去噪模块；第二阶段，利用扩散过程对每一层输出的特征进行加噪，并训练对应的去噪模块学习预测添加的噪声；第三阶段，在推理时将训练好的去噪模块参数与原始嵌入层参数进行融合，获得增强后的网络参数。该方法不依赖任何标签信息，可以在无监督条件下完成训练，且适用于 ResNet[12]、ViT[13]、Swin Transformer[17] 和 VMamba[18] 等多种骨干网络架构。

3.2　联合特征提取与特征去噪

本节详细介绍如何将扩散模型的去噪机制融入判别式骨干网络的特征提取过程中，构建联合特征提取与特征去噪的统一框架。

3.2.1 扩散过程建模

本方法借鉴扩散模型的基本框架[25]，在特征空间上构建前向扩散过程。与传统扩散模型在像素空间上操作不同，本方法以骨干网络各层输出的特征向量作为数据样本进行扩散建模。

设骨干网络包含 N 个级联的嵌入层，第 i 层输出的特征向量记为 F_i（$i = 1,2,\ldots,N$）。对于每一层的特征 F_i，通过不断添加高斯噪声来模拟其特征分布的前向扩散过程：

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) \triangleq \prod_{t=1}^{T} q(\mathbf{x}_t|\mathbf{x}_{t-1}) \tag{3.1}$$

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) \triangleq \mathcal{N}\left(\mathbf{x}_t; \sqrt{1-\beta_t}\,\mathbf{x}_{t-1}, \beta_t \mathbf{I}\right) \tag{3.2}$$

其中 $\mathbf{x}_0$ 表示骨干网络某一层输出的特征向量 F_i，t 表示扩散步数，β_t 为预先设定的噪声调度参数，$\mathbf{x}_t$ 表示经过 t 步扩散后获得的含噪样本。利用扩散过程的重参数化性质，可以直接从 $\mathbf{x}_0$ 一步获得任意步数 t 对应的含噪样本：

$$\mathbf{x}_t = \sqrt{\bar{a}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{a}_t}\,\boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \tag{3.3}$$

其中 $a_t = 1-\beta_t$，$\bar{a}_t = \prod_{s=1}^{t} a_s$ 为累积噪声调度系数。

在推理阶段，对骨干网络输出的特征执行 T 步反向去噪，以获得更干净、更具判别性的特征表示：

$$p_\theta(\mathbf{x}_{0:T}) \triangleq p(\mathbf{x}_T) \prod_{t=1}^{T} p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) \tag{3.4}$$

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) \triangleq \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)) \tag{3.5}$$

其中 $\mathbf{x}_T$ 表示推理阶段骨干网络输出的含噪特征，T 为去噪步数，控制去噪的幅度。通过 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 逐步去噪，最终获得去噪后的干净特征 $\mathbf{x}_0$。可以根据不同数据集和骨干网络的特点，调节 t 的大小以获得最优的去噪效果。

3.2.2 去噪网络训练

本方法的一个关键设计是将骨干网络的 N 个级联嵌入层重新解释为 N 步递归去噪过程。具体而言，为骨干网络的每一个嵌入层附加一个轻量级的去噪模块 $D_i(\cdot)$（$i = 1,2,\ldots,N$），在训练阶段冻结骨干网络的原始参数，仅优化这些去噪模块的参数。

训练过程的具体步骤如算法1所示。对于第 i 层，根据其在网络中的深度位置设定对应的扩散步数 $t = i$，即浅层对应较小的噪声幅度，深层对应较大的噪声幅

度。这一设计的直觉在于：随着特征在网络中逐层传播，累积的噪声逐渐增加，因此深层需要更强的去噪能力。对每一层的特征 F_i，首先按式（3.3）进行前向扩散获得含噪样本 $\mathbf{x}_t$，然后训练去噪模块 D_i 学习预测添加的噪声 $\boldsymbol{\epsilon}$，优化目标为最小化预测噪声与真实噪声之间的均方误差：

$$\mathscr{L}_p = \sum_{i=1}^{N} \|\boldsymbol{\epsilon}_i - D_{\theta_i}(\mathbf{x}_{t_i}, t_i)\|^2 \tag{3.6}$$

其中 $\boldsymbol{\epsilon}_i$ 为第 i 层采样的真实噪声，$D_{\theta_i}(\mathbf{x}_{t_i}, t_i)$ 为第 i 个去噪模块对噪声的预测。

Algorithm 1 特征去噪模块训练算法

输入： 骨干网络嵌入层数 N，各层提取的特征 $\{F_i\}_{i=1}^{N}$，待训练的去噪模块 $\{D_i(\cdot)\}_{i=1}^{N}$。

```
repeat
    for 每一层 i ∈ [N, 1] do
        t = i：根据层的顺序指定当前层的扩散步数 t。
        ε ~ N(0, I)：随机采样一个高斯噪声。
        x_t = √ā_t F_i + √(1 − ā_t) ε：按式（3.3）执行前向扩散。
        对 ∇_θ ‖ε − D_i(x_t, t)‖² 执行梯度下降步。
    end for
until 收敛
```

值得指出的是，本方法的训练过程完全不依赖标签信息，因为去噪目标函数式（3.6）本质上是一个生成式建模目标——通过学习特征的分布来实现去噪，无需任何标注信息的参与。这意味着该方法可以利用大量无标签数据进行训练，具有良好的实用性。同时，该方法也兼容有监督学习范式：当标签可用时，可以将任务特定的有监督损失 $\mathscr{L}_l$ 与去噪损失 $\mathscr{L}_p$ 进行加权组合：

$$\mathscr{L} = (1-\lambda)\,\mathscr{L}_l + \lambda\,\mathscr{L}_p \tag{3.7}$$

其中 λ 为平衡两个损失项的权重系数。实验结果表明，引入标签信息能够进一步提升特征增强的效果。

3.3　特征提取与去噪的参数融合

上一节所述的联合特征提取与去噪框架虽然能够有效提升特征的判别性，但在推理阶段需要额外执行去噪层的前向计算，引入了不可忽视的推理延迟。本节提出一种参数融合策略，将去噪层的参数合并至对应嵌入层的参数中，从理论上证明融合前后的数学等价性，从而在推理阶段完全消除额外开销。

3.3.1　双分支结构设计

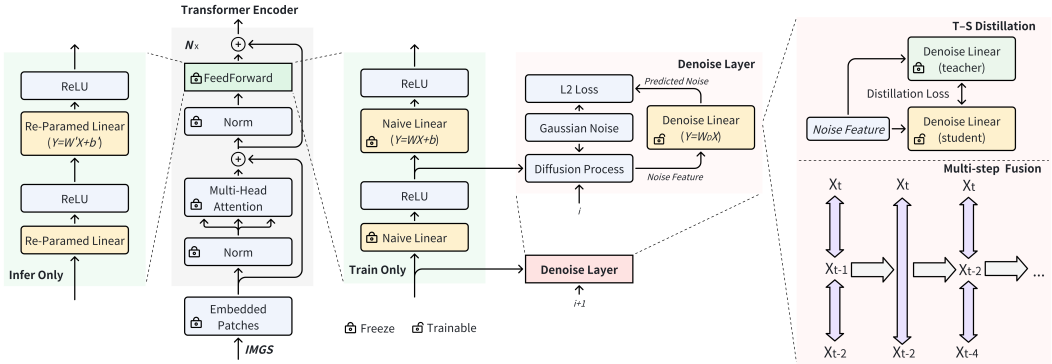

图 3.2　本章所提方法的训练与推理流程示意图
Fig. 3.2　Pipeline of the proposed method for training and inference

如图3.2所示，本方法将骨干网络（以 Vision Transformer 为例）中每一个 Transformer 编码层的线性层扩展为双分支结构：一个分支为原始的嵌入层（执行特征提取），另一个分支为新增的去噪层（执行特征去噪）。

在训练阶段（图3.2右侧 “Train Only’’ 部分），骨干网络的原始参数被冻结，仅训练新增的去噪层参数。去噪层的训练方法与第3.2节描述一致：将每一层的特征通过扩散过程加噪后，送入对应的去噪层进行噪声预测训练。图3.2右上方展示了教师--学生蒸馏和多步融合机制，这两项增强策略将在第四章中详细阐述。

在推理阶段（图3.2左侧 “Infer Only’’ 部分），通过参数重参数化技术，将双分支结构合并为单分支结构。具体而言，将原始嵌入层参数 W 替换为融合后的参数 W'，其中 W' 同时包含了特征提取和特征去噪的功能，但参数量与原始的 W 完全相同。这种设计思路借鉴了结构重参数化的理念[77]——在训练阶段使用更丰富的多分支结构以增强表达能力，在推理阶段将其融合为单一结构以保持高效。

需要指出的是，虽然本节以 Transformer 架构为例进行说明，但所提方法同样适用于 CNN 架构。只要骨干网络的嵌入层可以表示为线性变换 $Y = WX + b$ 的形式，本方法的参数融合策略即可直接应用。

3.3.2　参数融合数学推导

本小节给出从一步去噪到参数融合的完整数学推导，证明融合前后的严格等价性。

根据 DDPM[25] 的反向去噪公式，对特征的一步去噪过程可以表示为：

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{a_t}}\left(\mathbf{x}_t - \frac{1-a_t}{\sqrt{1-\bar{a}_t}} D_\theta(\mathbf{x}_t, t)\right) + \sigma_t \mathbf{z} \tag{3.8}$$

其中 $a_t = 1-\beta_t$，D_θ 为去噪网络的参数，σ_t 为噪声系数，$\mathbf{z} \sim \mathcal{N}(\mathbf{0},\mathbf{I})$。

设骨干网络某一嵌入层的线性变换为 $Y = WX + b$，其中 W 和 b 分别为该层的权重矩阵和偏置向量。将式（3.8）进行变换，并同时左乘 W，可以得到：

$$\frac{1}{\sqrt{a_t}} Y_t - Y_{t-1} = \frac{1-a_t}{\sqrt{a_t}\sqrt{1-\bar{a}_t}} D_\theta Y_t - \sigma_t \mathbf{z} \tag{3.9}$$

将 $Y_t = WX_t + b$ 代入并整理，可以获得一步去噪与线性变换合并后的简化形式：

$$\begin{cases} Y_{t-1} = \left[W - C_1(t) W W_D\right] X_t + W C_2(t) C_3 + b \\ C_1(t) = \dfrac{1-a_t}{\sqrt{a_t}\sqrt{1-\bar{a}_t}} \\ C_2(t) = \dfrac{1-\bar{a}_{t-1}}{1-\bar{a}_t}\beta_t \\ C_3 = \mathbf{z} \sim \mathcal{N}(\mathbf{0},\mathbf{I}) \end{cases} \tag{3.10}$$

其中 W_D 为去噪模块 $D_\theta(\mathbf{x}_t, t)$ 的参数矩阵，X_t 为该线性层的输入，Y_t 为原始线性层的输出，Y_{t-1} 为经过一步去噪后的输出。

式（3.10）揭示了参数融合的核心思想：在推理阶段，可以将原始参数 W 替换为融合后的参数：

$$W' = W - C_1(t) W W_D \tag{3.11}$$

$$b' = W C_2(t) C_3 + b \tag{3.12}$$

从而将特征提取操作 $Y = WX + b$ 与一步去噪操作统一为 $Y_{t-1} = W'X_t + b'$。融合后的 W' 与原始 W 具有相同的维度，因此不引入任何额外的参数量和计算量。这是一种零额外推理开销的特征增强策略。

由于骨干网络中各层之间存在级联关系，不同层设置不同的 t 值。根据算法2的设计，第 i 层使用 $t = i$，使得级联的 N 个嵌入层的逐层一步去噪（每层完成 $Y_t \to Y_{t-1}$）等价于完整的 N 步去噪过程（$Y_N \to Y_0$），从而保证了去噪过程的连续性。

进一步地，若需要增大单层的去噪幅度，可以将一步去噪扩展为两步去噪。以下给出两步去噪的推导过程。对 Y_t 的一步去噪为：

$$\frac{1}{\sqrt{a_t}} Y_t - Y_{t-1} = C_1(t) D_\theta Y_t - \sigma_t \mathbf{z} \tag{3.13}$$

对 Y_{t-1} 的一步去噪为：

$$\frac{1}{\sqrt{a_{t-1}}} Y_{t-1} - Y_{t-2} = C_1(t-1) D_\theta Y_{t-1} - \sigma_{t-1} \mathbf{z} \tag{3.14}$$

Algorithm 2 参数融合推理算法

输入： 骨干网络嵌入层数 N，各层特征 $\{F_i\}_{i=1}^N$，已训练的去噪模块参数 $\{W_{D_i}\}_{i=1}^N$，骨干网络预训练参数 $\{W_i\}_{i=1}^N$ 和 $\{b_i\}_{i=1}^N$。

输出： 去噪后的特征 F^0。

1: **for** 每一层 $i \in [N,1]$ **do**
2: 　$t = i$：根据当前层的深度设定去噪幅度。
3: 　$W' = [W_i - C_1(t)W_iW_{D_i}]$，$b' = W_iC_2(t)C_3 + b_i$：按式（3.11）--（3.12）进行参数融合。
4: 　$F^{t-1} = W'F^t + b'$：融合特征提取与特征去噪。
5: **end for**
6: **返回** F^0

通过消去 Y_{t-1} 并将 $Y_t = WX_t + b$ 代入，可得两步去噪的融合公式：

$$\begin{cases} Y_{t-2} = W''X_t + C'' \\ W'' = \dfrac{1}{\sqrt{a_{t-1}}}\left\{\dfrac{W}{\sqrt{a_t}} - \left[C_1(t) + C_1(t-1)\right]WW_D + \sqrt{a_t}C_1(t-1)C_1(t)WW_DW_D\right\} \\ C'' = \dfrac{1}{\sqrt{a_{t-1}}}[WC_2(t) + \sqrt{a_t}WC_2(t-1) - \sqrt{a_t}C_1(t-1)C_2(t)WW_D]\mathbf{z} + b \end{cases} \tag{3.15}$$

上述推导表明，单个嵌入层可以完成两步去噪，且其结果仍然可以通过参数融合表示为一次线性变换。此时为保证整体去噪过程的连续性，各层的 t 值应按步长 2 递减。这一扩展机制使得去噪幅度可以根据实际需求灵活调节。

本章所提的算法基于特征级别的去噪，能够迁移至各类下游判别式任务。该算法在每一层上对特征进行去噪，能够更好地去除各阶段的噪声——因为推理阶段的噪声来自多个方面，既可能是输入图像中的噪声，也可能是在网络传播过程中产生的噪声。逐层去噪避免了噪声的累积效应，从而获得更高质量的特征输出。此外，可以通过控制 t、β_t 和去噪步数来调节去噪强度，以适应不同应用场景中数据的噪声特性，体现了良好的通用性和灵活性。

3.4 本章实验设计

3.4.1 实验设置与评价指标

为全面验证本章所提方法的有效性和通用性，分别在行人重识别、图像分类、目标检测和图像分割四类判别式视觉任务上进行实验评估。

在行人重识别任务中，选取四个广泛使用的基准数据集：DukeMTMC-reID[88]、

Market-1501[89]、MSMT17[90] 和 CUHK-03[91]。这四个数据集涵盖了行人重识别中多种典型的挑战场景，包括跨摄像头视角变化、背景干扰和姿态差异等。评价指标采用平均精度均值（mean Average Precision, mAP）和 Rank-1 准确率。mAP 综合衡量检索结果在所有查询上的平均精度，Rank-1 表示检索结果中排名最高的图像为正确匹配的概率。所有结果基于单查询设定。

在图像分类任务中，选取大规模通用分类数据集 ImageNet-1k[19] 以及三个细粒度分类数据集 CUB200[44]、Oxford-Pet[45] 和 Flowers[46]。ImageNet-1k 包含 1000 个类别、超过 120 万张训练图像，是验证分类模型通用能力的标准基准。三个细粒度数据集分别聚焦鸟类、宠物和花卉的细粒度类别识别。评价指标采用 Top-1 准确率和 Top-5 准确率。

在目标检测任务中，选取 COCO[92] 数据集。COCO 是目标检测领域最常用的大规模基准，包含 80 个目标类别和超过 11 万张训练图像。评价指标采用平均精度（AP）及其在不同 IoU 阈值下的变体 AP_{50} 和 AP_{75}。

在图像分割任务中，选取 ADE20K[23] 数据集。ADE20K 包含约 2 万张图像和 150 个语义类别，广泛用于语义分割模型的评估。评价指标采用平均交并比（mIoU）和边界交并比（B-IoU）。

3.4.2　实现细节与训练策略

所有实验在配备两块 NVIDIA RTX 3090 GPU 的服务器上进行，处理器为 Intel Xeon Gold 5218R（2.10GHz）。训练轮次设为 120 个 epoch，初始学习率设为 0.0004，训练阶段的批量大小为 64，推理阶段的批量大小为 256，扩散步数 t 设为 1000。

在训练策略方面，为了更好地约束去噪特征对下游任务的适配性，采用交替微调的训练方式。具体而言，本方法的参数与基线模型的参数交替训练：当训练一部分参数时，冻结其余参数进行微调，每次微调 10 个 epoch，总轮次为 120 个 epoch。在评估时，对相同设置下的实验进行 5 次独立运行并取平均值，以确保实验结果的可靠性。

3.5　实验结果与分析

3.5.1　基础效果与对比分析

本节首先验证所提方法在多个判别式任务上的基础有效性，然后与现有先进方法进行对比分析。

表3.1展示了本章方法在四类代表性判别式任务上的实验结果。可以看到，在

不增加任何模型参数的前提下，所提方法在图像分类、行人重识别、目标检测和图像分割四个任务上均取得了稳定且显著的性能提升。

表 3.1　本章方法在多种判别式任务上的实验结果
Table 3.1　Experimental results on multiple discriminative tasks

任务	模型	骨干网络	数据集	指标	基线	+ 本章方法
分类	SwinT	SwinV2-T	ImageNet-1k	acc@1	81.82%	82.13%
检索	TransReID-SSL	ViT-S	MSMT17	mAP	66.30%	67.33%
检测	Mask-RCNN	Swin-T	COCO	AP	42.80%	44.30%
分割	FCN	ResNet-50	ADE20K	BIoU	28.70%	29.90%

接下来，本节分析标签信息对本方法性能的影响。如第3.2节所述，本方法本质上是一种无标签的去噪训练方式，但也可以在标签可用时通过引入有监督损失来进一步提升性能。表3.2展示了在 TransReID-SSL（ViT-small 骨干网络）上的对比实验结果。

表 3.2　标签信息对本章方法性能的影响分析
Table 3.2　Analysis of the effect of label information

方法	DukeMTMC mAP(%)	MSMT17 mAP(%)	Market1501 mAP(%)	CUHK-03 mAP(%)
TransReID-SSL（基线）	81.20	66.30	91.20	83.50
+ 本章方法（无标签）	81.72	66.87	91.82	83.72
+ 本章方法（有标签）	82.12	67.33	92.05	84.11
+ 本章方法（合并数据集）	81.78	66.99	91.80	83.86

从表3.2中可以得出以下三点结论：

（1）无标签训练的有效性。与基线方法（第 1 行）相比，在无标签条件下添加本章所提方法（第 2 行）即可在四个数据集上分别获得 0.52%、0.57%、0.62% 和 0.22% 的 mAP 提升，验证了该方法确实具备对特征的有效去噪能力。

（2）标签信息的互补性。引入标签信息进行有监督训练（第 3 行）后，相比无标签版本在四个数据集上进一步获得 0.32%∼0.70% 的 mAP 提升，表明该去噪方法具有良好的标签兼容性，无论在有监督还是无监督条件下均能有效提升特征质量。

（3）跨数据集泛化能力。将四个数据集合并进行无标注训练（第 4 行），其性能优于在单个数据集上训练的无标签版本（第 2 行），说明引入更多无标签数据可以进一步增强去噪模块的泛化能力，印证了该方法良好的可扩展性。

进一步地，表3.3展示了本方法与当前先进行人重识别方法的对比结果。

表 3.3　与先进行人重识别方法的对比实验
Table 3.3　Comparison with state-of-the-art ReID methods

方法	骨干网络	MSMT17		Market1501		DukeMTMC		CUHK
		mAP	R1	mAP	R1	mAP	R1	mAP
MGN[93]	ResNet-50	–	–	86.90	95.70	78.40	88.70	67.40
OSNet[94]	OSNet	52.90	78.70	84.90	94.80	73.50	88.60	–
BAT-net[95]	GoogLeNet	56.80	79.50	87.40	95.10	77.30	87.70	76.10
ABD-Net[96]	ResNet-50	60.80	82.30	88.30	95.60	78.60	89.00	–
RGA-SC[97]	ResNet-50	57.50	80.30	88.40	96.10	–	–	77.40
ISP[98]	HRNet-W32	–	–	88.60	95.30	80.00	89.60	74.10
CDNet[99]	CDNet	54.70	78.90	86.00	95.10	76.80	88.60	–
Nformer[100]	ResNet-50	59.80	77.30	91.10	94.70	83.50	89.40	78.00
TransReID[101]	ViT-base	61.80	81.80	87.10	94.60	79.60	89.00	82.30
TransReID-SSL[86]	ViT-small	66.30	84.80	91.20	95.80	81.20	87.80	83.50
TransReID-SSL	ViT-base	75.00	89.50	93.10	96.52	84.10	92.60	87.80
CLIP-ReID[43]	ViT-base	75.80	89.70	90.50	95.40	83.10	90.80	–
TransReID + 本章方法	ViT-base	62.23	82.02	87.25	94.63	80.12	89.33	82.44
TransReID-SSL + 本章方法	ViT-small	67.33	85.50	92.05	96.68	82.12	88.72	84.11
TransReID-SSL + 本章方法	ViT-base	75.35	89.62	93.26	96.55	84.31	92.90	88.08
CLIP-ReID + 本章方法	ViT-base	76.30	90.60	91.10	95.80	83.70	91.60	–

从表3.3可以观察到以下规律：

（1）本方法在 ViT-base 骨干网络上的四个数据集中几乎达到了所有指标的最优性能，表明所提的特征去噪策略能够有效提升当前先进方法的性能上限。

（2）添加本方法后的模型在所有数据集上均优于使用相同骨干网络的原始方法。值得注意的是，小规模骨干网络（ViT-small）添加本方法后的性能提升幅度大于大规模骨干网络（ViT-base）。这一现象的合理解释是：本方法本质上是一种去噪模块，用于去除推理阶段特征中包含的噪声。对于参数量较大的骨干网络，其

提取的特征已经具有较好的表达能力，特征中残留的噪声相对较少，因此去噪的提升空间有限。而对于参数量较小、拟合能力有限的骨干网络，其提取的特征在推理阶段包含较多噪声，去噪操作能够获得更显著的改善效果。

（3）本方法具有良好的模型无关性，可以增量式地应用于任意现有骨干网络的每一层，尤其对于性能较弱的骨干网络，去噪增强的效果更为显著。

3.5.2 效率与开销验证

本章方法的一个核心特性是零额外推理开销。本节通过实验验证参数融合的有效性，并对比不同去噪策略的推理效率。表3.4展示了基于 TransReID-SSL（ViT-small 骨干网络）的对比实验结果。

表 3.4　参数融合性能与推理效率分析
Table 3.4　Analysis of parameter fusion performance and inference efficiency

数据集	基线	+ 末端去噪	+ 本章方法
DukeMTMC	81.20%	81.56%	82.12%
MSMT17	66.30%	66.81%	67.33%
Market1501	91.20%	91.07%	92.05%
CUHK-03	83.50%	83.59%	84.11%
推理时间	0.34s	0.39s (+15%)	0.34s (+0%)

从表3.4中可以得出以下结论：与基线方法相比，在模型末端附加独立的去噪模块（‘‘末端去噪’’）能够在一定程度上提升性能，验证了基于特征的去噪确实有效。然而，这种方式也带来了约 15% 的额外推理延迟，因为它在模型末端增加了独立的、参数不可融合的去噪层。

采用本章所提方法后，在四个数据集上均获得了更大幅度的提升。这得益于逐层去噪的设计——由于推理阶段的噪声来自多个方面（输入图像噪声和网络传播噪声），在每一层进行去噪可以避免噪声的逐层累积，获得更高质量的特征输出。更重要的是，由于参数融合机制能够将去噪模块的参数合并至原始嵌入层参数中，本方法不引入任何额外的推理延迟，实现了零额外推理开销的特征增强。

为进一步验证实验的公平性，表3.5对比了基线方法和本章方法在相同额外训练轮次下的性能变化。

实验结果表明，基线方法在增加训练轮次后性能没有显著提升，甚至略有下降（过拟合），而添加本章方法后性能随训练轮次持续提升。这证明所观察到的性

表 3.5　相同训练轮次下的公平性对比实验
Table 3.5　Fairness comparison under the same training epochs

训练轮次	120	160	200	240
基线	81.18%	81.19%	81.18%	81.16%
+ 本章方法	81.18%	81.64%	82.00%	82.12%

能改善确实来源于所提方法的去噪增强效果，而非简单的训练时间增加所致。

3.6　本章小结

本章提出了一种面向无额外推理成本的特征增强算法，通过将扩散模型的去噪过程与判别式骨干网络的特征提取过程进行统一建模，实现了在不增加推理开销的前提下有效增强特征表示的判别性。

本章的主要工作和贡献包括以下几个方面。首先，提出了一种联合特征提取与特征去噪的统一框架，将骨干网络中级联的 N 个嵌入层重新解释为 N 步递归去噪过程，使得特征的提取与去噪在网络的逐层传播中同步完成。其次，设计了一种参数融合机制，从理论上严格证明了去噪层参数与嵌入层参数融合后的数学等价性，通过将训练好的去噪参数合并为 $W' = W - C_1(t)WW_D$，在推理阶段完全消除了去噪操作带来的额外计算开销，实现了零额外推理成本的特征增强。此外，该方法采用无标签训练范式，不依赖任何标注信息即可完成去噪模块的训练，同时兼容有监督学习，当标签可用时能够进一步提升性能。

在实验验证方面，本章在行人重识别（DukeMTMC、Market-1501、MSMT17、CUHK-03）、图像分类（ImageNet-1k、CUB200、Oxford-Pet、Flowers）、目标检测（COCO）和图像分割（ADE20K）等多个代表性视觉任务上进行了全面的实验评估。结果表明，所提方法能够即插即用地应用于 ResNet、ViT、Swin Transformer 等多种骨干网络，在不增加任何推理开销的前提下稳定提升各项判别式任务的性能指标。参数融合验证实验进一步确认了零额外推理延迟的特性。

然而，本章方法也存在一定的局限性：由于去噪模块需要被设计为与嵌入层参数可融合的轻量化结构，其有限的参数量制约了对复杂噪声分布的建模能力，导致去噪精度存在提升空间。此外，当骨干网络的层数有限时，可用的去噪步数也相应受限，影响了整体去噪幅度。这些问题将在第四章中通过引入教师--学生蒸馏和多步去噪融合策略加以解决。

4 基于模型蒸馏的特征增强算法研究

第三章提出的面向无额外推理成本的特征增强算法，通过参数融合机制实现了去噪操作的零额外推理开销。然而，该方法存在两个固有的局限性：其一，去噪模块必须被设计为与嵌入层参数可融合的轻量化结构，有限的参数规模制约了其对复杂噪声分布的建模能力，导致去噪精度存在提升空间；其二，去噪步数受限于骨干网络的层数，当网络深度有限时，可用的去噪幅度相应受限。针对上述两个问题，本章提出基于模型蒸馏的特征增强算法，引入两项协同增强策略加以解决。第4.1节分析从参数融合到蒸馏增强的问题演进；第4.2节提出教师--学生蒸馏去噪框架以增强轻量级去噪模块的建模能力；第4.3节设计有限去噪深度下的增强策略，包括多轮单层去噪和多步去噪融合；第4.4节讨论无监督与有监督学习范式的统一；第4.5节和第4.6节分别介绍实验设置与结果分析；最后在第4.7节对本章工作进行总结。

4.1 从参数融合到蒸馏增强的问题演进

第三章所提方法的核心优势在于通过参数融合实现零额外推理开销，但这一设计在带来高效性的同时，也对去噪模块的结构施加了严格约束。具体而言，为了保证去噪层参数 W_D 能够与嵌入层参数 W 进行等价融合（式（3.11）），去噪模块必须是一个与嵌入层维度匹配的线性变换。这意味着去噪模块的参数量与原始嵌入层相当，其表达能力受到了内在限制。

从噪声建模的角度分析，轻量级去噪模块面临的核心挑战在于：实际判别式任务中的特征噪声往往具有复杂的、非各向同性的分布特征。例如，在行人重识别任务中，噪声可能来源于遮挡区域的特征坍缩、跨视角变化引起的特征漂移以及背景杂乱造成的干扰信号，这些噪声的分布具有高度的空间相关性和任务依赖性。有限参数规模的去噪模块难以精确捕获这些复杂的噪声模式，导致噪声预测存在系统性偏差。

另一方面，第三章方法中每一层执行一步去噪（$Y_t \to Y_{t-1}$），整个骨干网络的 N 个嵌入层完成 N 步去噪（$Y_N \to Y_0$）。对于层数较少的骨干网络（如 12 层的 ViT-small），可用的去噪步数仅为 12 步，这在面对高噪声场景时可能不足以将特征充分去噪至干净分布。虽然第三章已经推导了两步去噪的扩展公式（式（3.15）），但简单地增加每层的去噪步数会引入离散化误差的累积问题，需要更加精细的策略来保证去噪质量。

基于上述分析，本章提出两项互补的增强策略：

（1）教师--学生蒸馏增强。利用一个表达能力更强的教师网络在训练阶段指导轻量级学生去噪模块的学习。教师网络能够更准确地捕获噪声的结构化模式，通过蒸馏将这种能力传递给学生模块，有效校正学生的噪声预测偏差，从而在不改变推理结构的前提下提升去噪精度。

（2）多步去噪融合。通过多轮单层去噪和逐步蒸馏，将多步去噪轨迹压缩为等效的单步操作。这一策略在有限的网络层数下模拟更深的去噪轨迹，增强去噪幅度，同时保持参数融合的零额外推理开销特性。

这两项策略从不同维度解决第三章方法的局限性：蒸馏增强提升去噪的精度，多步融合扩大去噪的幅度。两者协同作用，使得增强后的方法能够在保持零推理开销的前提下获得更强的特征去噪能力。

4.2 教师--学生蒸馏去噪框架

本节提出教师--学生蒸馏去噪框架，通过利用高容量教师网络的知识指导轻量级学生去噪模块的训练，在不改变推理阶段网络结构的前提下，显著提升去噪模块的噪声预测精度。

4.2.1 问题分析

如第4.1节所述，第三章方法中的去噪模块 D_θ 被设计为与嵌入层维度匹配的线性变换，以满足参数融合的需求。然而，线性变换的表达能力受限于其参数空间的维度，面对高维特征空间中复杂的噪声分布时，其噪声预测 $\hat{\boldsymbol{\epsilon}}_S(\mathbf{x}_t, t)$ 与真实噪声 $\boldsymbol{\epsilon}$ 之间存在不可忽视的系统性偏差。

具体而言，这种偏差的来源可以从两个方面理解。首先，从函数逼近的角度，线性去噪模块只能学习噪声分布的一阶近似，而实际噪声分布中的高阶相关性（如不同通道之间的噪声耦合）无法被精确建模。其次，从优化的角度，当去噪损失 $\mathscr{L}_p = \sum_{i=1}^{N} \|\boldsymbol{\epsilon}_i - D_{\theta_i}(\mathbf{x}_{t_i}, t_i)\|^2$ 收敛后，残余误差反映的是模型容量的上限而非训练不充分。

为了突破这一能力瓶颈，本章借鉴知识蒸馏[83] 的思想：在训练阶段引入一个参数量更大、表达能力更强的教师网络 D_T，通过教师对噪声分布的更精确建模来指导学生网络 D_S 的学习。关键在于，教师网络仅在训练阶段使用，推理阶段仍然只使用轻量级学生网络并通过参数融合消除额外开销，从而保持零额外推理成本的核心特性。

4.2.2 蒸馏框架设计

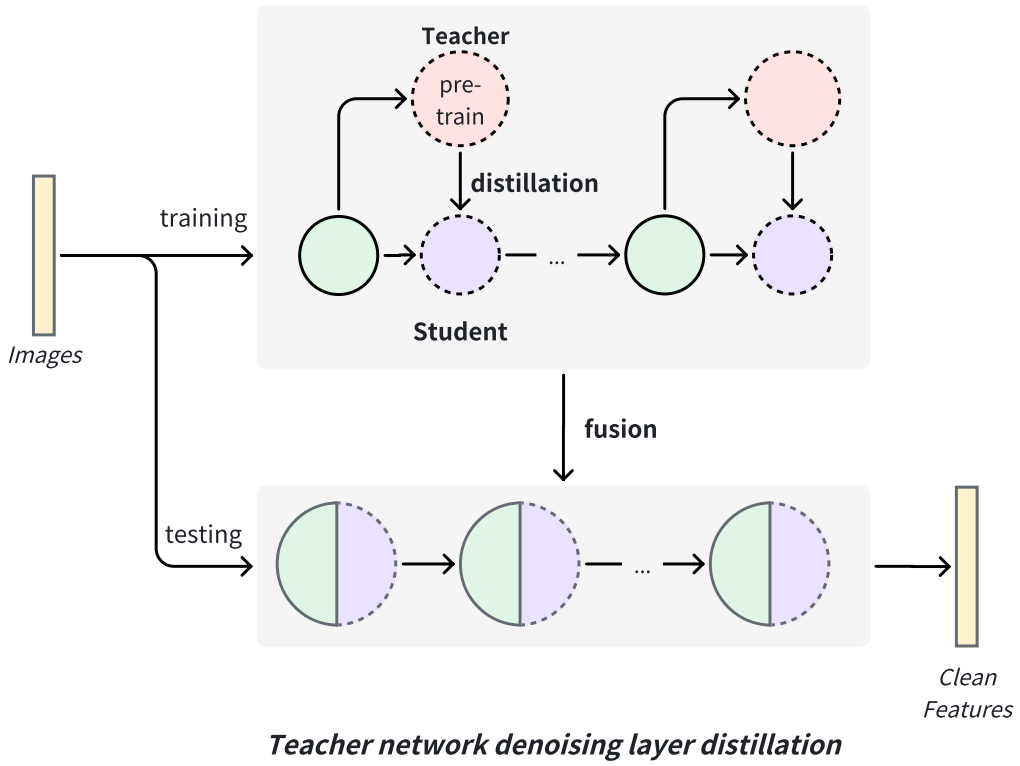

图 4.1 教师--学生蒸馏去噪框架示意图
Fig. 4.1 Illustration of the teacher–student denoising layer distillation framework

如图4.1所示，本方法的蒸馏框架包含三个阶段：教师训练、知识蒸馏和参数融合推理。

在教师训练阶段，构建一个高容量的教师去噪网络 D_T。与学生网络 D_S 相比，教师网络采用更宽或更深的网络结构，从而拥有更强的噪声分布建模能力。对于骨干网络第 i 层的含噪特征 $\mathbf{x}_{t_i}$，教师网络输出的噪声预测为 $\hat{\boldsymbol{\epsilon}}_T(\mathbf{x}_{t_i}, t_i)$，其训练目标与第三章相同：

$$\mathscr{L}_{teacher} = \sum_{i=1}^{N} \|\boldsymbol{\epsilon}_i - \hat{\boldsymbol{\epsilon}}_T(\mathbf{x}_{t_i}, t_i)\|^2 \tag{4.1}$$

由于教师网络不受参数融合约束，其参数量可以根据实际需求灵活设定，因此能够学习到更加精确的噪声分布估计。

在知识蒸馏阶段，利用已训练好的教师网络作为软标签来指导学生网络的训练。具体而言，对于相同的含噪输入 $\mathbf{x}_{t_i}$，教师网络的噪声预测 $\hat{\boldsymbol{\epsilon}}_T(\mathbf{x}_{t_i}, t_i)$ 作为蒸馏目标，学生网络通过最小化与教师预测之间的差异来学习：

$$\mathscr{L}_{distill} = \sum_{i=1}^{N} \|\hat{\boldsymbol{\epsilon}}_S(\mathbf{x}_{t_i}, t_i) - \hat{\boldsymbol{\epsilon}}_T(\mathbf{x}_{t_i}, t_i)\|_2^2 \tag{4.2}$$

其中 $\hat{\epsilon}_S$ 和 $\hat{\epsilon}_T$ 分别为学生和教师网络的噪声预测。

将蒸馏损失与原始去噪损失进行加权组合，得到学生网络的整体训练目标：

$$\mathscr{L}_{total} = \lambda_p \mathscr{L}_{denoise} + \lambda_d \mathscr{L}_{distill} \tag{4.3}$$

其中 λ_p 和 λ_d 为平衡两个损失项的权重系数，$\mathscr{L}_{denoise}$ 为第三章定义的去噪损失（式（3.6））。通过联合优化，学生网络既能从真实噪声标签中学习基本的去噪能力，又能从教师的预测中获取更精细的噪声结构信息。

教师--学生蒸馏训练的完整算法如算法3所示。

Algorithm 3 教师--学生蒸馏训练算法

输入： 各层特征 $\{F_i\}_{i=1}^N$，学生去噪模块 $\{D_i^S(\cdot)\}_{i=1}^N$，教师去噪模块 $\{D_i^T(\cdot)\}_{i=1}^N$，权重系数 λ_p 和 λ_d。

```
repeat
  for 每一层 i ∈ [N, 1] do
    t = i；采样噪声 ε ~ N(0, I)。
    x_t = √ā_t F_i + √(1 − ā_t) ε：执行前向扩散。
    教师预测：ε̂_T = D_i^T(x_t, t)。
    学生预测：ε̂_S = D_i^S(x_t, t)。
    计算损失 L = λ_p ‖ε − ε̂_S‖² + λ_d ‖ε̂_S − ε̂_T‖²。
    对学生参数执行梯度下降步。
  end for
until 收敛
```

通过蒸馏训练，学生去噪模块能够继承教师网络对噪声分布的更精确估计。在推理阶段，仅使用训练好的学生网络参数，按照第三章的参数融合方法（式（3.11）--（3.12））将其合并至骨干网络的嵌入层中，不引入任何额外的推理开销。这种"训练时增强、推理时融合" 的设计理念，使得蒸馏带来的性能提升能够在保持零推理成本的前提下得到保留。

4.3 有限去噪深度下的增强策略

第4.2节通过蒸馏提升了去噪模块的预测精度，但并未解决去噪幅度受限于网络层数的问题。本节提出两种互补的增强策略：多轮单层去噪通过在单层上反复执行去噪来模拟更深的去噪轨迹；多步去噪融合通过逐步蒸馏将多步去噪压缩为等效的单步操作。

4.3.1 多轮单层去噪

多轮单层去噪的核心思想是：在不增加网络层数的前提下，允许单个去噪层在同一特征上迭代执行多轮去噪，从而模拟更长的去噪轨迹。

具体而言，对于骨干网络中某一层对应的去噪模块，其基本的一步去噪操作定义为：

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{a_t}}\left(\mathbf{x}_t - \frac{1-a_t}{\sqrt{1-\bar{a}_t}}\epsilon_\theta(\mathbf{x}_t, t)\right) + \delta_t \mathbf{z} \tag{4.4}$$

其中 $\epsilon_\theta(\mathbf{x}_t, t)$ 为去噪模块预测的噪声，$\delta_t \mathbf{z}$ 为高斯扰动项。

假设去噪模块为线性层 $G_\theta(\mathbf{x}_t, t) = W\mathbf{x}_t + b$，式（4.4）可改写为仿射变换形式。定义：

$$\begin{cases} A_t = \sqrt{a_t}\left(\mathbf{I} - \dfrac{1-a_t}{\sqrt{1-\bar{a}_t}}W\right) \\ C_t = -\dfrac{1-a_t}{\sqrt{1-\bar{a}_t}}b \end{cases} \tag{4.5}$$

则一步去噪的递推关系简化为：

$$\mathbf{x}_{t-1} = A_t \mathbf{x}_t + C_t + \delta_t \mathbf{z} \tag{4.6}$$

将式（4.6）递推 k 步，可以得到从 $\mathbf{x}_t$ 到 $\mathbf{x}_{t-k}$ 的多轮去噪结果：

$$\begin{aligned} \mathbf{x}_{t-k} = &\left(\prod_{j=0}^{k-1} A_{t-j}\right)\mathbf{x}_t + \sum_{j=0}^{k-1}\left(\prod_{m=j+1}^{k-1} A_{t-m}\right)C_{t-j} \\ &+ \sum_{j=0}^{k-1}\left(\prod_{m=j+1}^{k-1} A_{t-m}\right)\delta_{t-j}\mathbf{z} \end{aligned} \tag{4.7}$$

其中 $\prod_{m=j+1}^{k-1} A_{t-m}$ 为系数矩阵的连乘项。由于 A_t 和 C_t 均可预先计算，上述多轮去噪的结果仍然可以表示为关于 $\mathbf{x}_t$ 的仿射变换，从而支持与嵌入层参数的融合。

将多轮去噪结果与线性嵌入层 $Y = W_L\mathbf{x} + b_L$ 组合后，最终的特征输出为：

$$Y_0 = W_L\big(A_t \mathbf{x}_t + C_t + \delta_t \mathbf{z}\big) + b_L \tag{4.8}$$

该表达式可以抽象为融合函数 $Y_0 = f_{\text{fusion}}(\mathbf{x}_t, t, W_L, b_L, W, b)$，其中所有中间变量均可在推理前预计算完成。

4.3.2 多步去噪融合

多轮单层去噪虽然能够增加去噪幅度，但直接递推可能引入离散化误差的累积。为此，本节进一步引入多步去噪融合策略，借鉴渐进蒸馏[39] 的思想，通过教师网络的多步去噪结果指导学生网络学习等效的单步去噪。

该策略的实施分为三个阶段，如算法4所示。

在第一阶段（教师多步去噪），利用已训练好的教师去噪网络 D_T，采用类似 DDIM[38] 的跳步采样规则，对含噪特征 $\mathbf{z}_t$ 执行多步（$k \geq 2$ 步）去噪，得到去噪后的特征 $\hat{\mathbf{x}}$：

$$\mathbf{z}_t \xrightarrow{D_T, k\text{步}} \hat{\mathbf{x}} \tag{4.9}$$

教师网络的基础训练目标为标准的去噪损失：

$$\mathscr{L}_\theta = \|\boldsymbol{\epsilon} - \hat{\boldsymbol{\epsilon}}_\theta(\mathbf{z}_t, t)\|_2^2 \tag{4.10}$$

其中 $\boldsymbol{\epsilon}$ 为采样的高斯噪声，$\hat{\boldsymbol{\epsilon}}_\theta$ 为教师的噪声预测。

在第二阶段（学生单步预测），学生网络 D_S 对相同的含噪输入 $\mathbf{z}_t$ 执行单步预测，直接输出去噪结果 $\hat{\mathbf{x}}_S$。学生网络的训练目标是逼近教师多步去噪的结果：

$$\mathscr{L}_{fusion} = w(\lambda_t)\,\|\hat{\mathbf{x}} - \hat{\mathbf{x}}_S(\mathbf{z}_t, t)\|_2^2 \tag{4.11}$$

其中 $\hat{\mathbf{x}}$ 为教师多步去噪的输出，$\hat{\mathbf{x}}_S(\mathbf{z}_t, t)$ 为学生的单步预测，$w(\lambda_t)$ 为与时间步相关的加权函数。

在第三阶段（参数融合推理），训练完成后的学生网络参数按照第三章的融合公式合并至骨干网络嵌入层，实现零额外推理开销的多步去噪效果。

这一策略的关键优势在于：教师网络通过多步迭代能够沿着更精确的去噪轨迹恢复干净特征，而学生网络通过蒸馏学习将这一多步轨迹压缩为单步操作。与直接在单层上递推多轮相比，多步去噪融合通过教师的轨迹引导有效减少了离散化误差的累积，同时保持了参数融合的可行性。实验中，模拟轮数 k 通常取较小值（$k = 2 \sim 3$），在获得显著提升的同时避免过度增加训练复杂度。

4.4 无监督与有监督学习范式

本章所提的教师--学生蒸馏增强和多步去噪融合策略，与第三章的基础方法一样，本质上均为生成式建模框架——通过学习特征的噪声分布来实现去噪，不需要任何标签信息的参与。因此，整个训练过程可以在完全无监督的条件下完成。

在无监督训练模式下，总训练损失仅包含去噪相关的损失项：

$$\mathscr{L}_{unsup} = \lambda_p \mathscr{L}_{denoise} + \lambda_d \mathscr{L}_{distill} + \lambda_f \mathscr{L}_{fusion} \tag{4.12}$$

其中 $\mathscr{L}_{denoise}$ 为基础去噪损失（式（3.6）），$\mathscr{L}_{distill}$ 为蒸馏损失（式（4.2）），$\mathscr{L}_{fusion}$ 为多步融合损失（式（4.11）），λ_p、λ_d 和 λ_f 为各项的平衡系数。

Algorithm 4 多步去噪融合算法

输入： 训练样本 $\mathbf{x}$，扩散步数 t，噪声调度 $\{\beta_t\}$，教师去噪网络 D_T，学生去噪网络 D_S。

输出： 融合后的学生模型，具备单步实现多步去噪的能力。

阶段一：训练教师网络。
for 每个小批量 $\mathbf{x}$ **do**
  采样噪声 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。
  前向扩散：$\mathbf{z}_t = \sqrt{\bar{a}_t}\,\mathbf{x} + \sqrt{1-\bar{a}_t}\,\boldsymbol{\epsilon}$。
  教师预测噪声 $\hat{\boldsymbol{\epsilon}}_T = D_T(\mathbf{z}_t, t)$。
  更新教师参数，最小化 $\mathscr{L}_\theta = \|\boldsymbol{\epsilon} - \hat{\boldsymbol{\epsilon}}_T\|_2^2$。
end for
阶段二：教师多步去噪。
for 每个训练步 **do**
  教师执行多步去噪 $\mathbf{z}_t \to \mathbf{z}_{t-k} \to \hat{\mathbf{x}}$，跳步间隔 $k \geq 2$。
end for
阶段三：学生单步学习。
for 每个小批量 **do**
  学生单步预测 $\hat{\mathbf{x}}_S = D_S(\mathbf{z}_t, t)$。
  计算融合损失 $\mathscr{L}_{fusion} = w(\lambda_t)\|\hat{\mathbf{x}} - \hat{\mathbf{x}}_S\|_2^2$。
  更新学生参数。
end for
返回训练好的学生模型。

这意味着本方法可以利用大量无标签数据进行训练，具有良好的实用性。例如，在行人重识别任务中，可以将多个数据集的无标签图像合并进行去噪模块的训练，从而获得泛化能力更强的去噪参数。

当标签信息可用时，可以将任务特定的有监督损失 $\mathscr{L}_l$ 引入训练框架，与去噪损失进行加权组合：

$$\mathscr{L}_{sup} = (1-\lambda)\,\mathscr{L}_l + \lambda\,\mathscr{L}_{unsup} \tag{4.13}$$

其中 λ 为平衡有监督损失与去噪损失的权重系数。有监督信号能够为去噪模块提供任务层面的约束，使去噪方向更加契合下游任务的需求。第三章的实验已经初步验证了标签信息的互补性（表3.2），本章将在更广泛的任务和骨干网络上进一步验证这一结论。

值得指出的是，无监督与有监督范式的统一是本方法的一个重要特点。在实际应用中，许多场景下标注数据稀缺或获取成本高昂，而无标签数据则相对充裕。本方法可以首先利用大量无标签数据完成去噪模块的预训练，再在少量标注数据

上进行有监督微调，从而在标注资源有限的条件下充分发挥去噪增强的能力。

4.5 本章实验设计

为验证本章所提教师--学生蒸馏增强和多步去噪融合策略的有效性，在第三章实验的基础上设计了消融实验和更大规模的跨任务实验。

4.5.1 消融实验设计

消融实验旨在分离并量化各增强模块的独立贡献及其互补性。具体而言，在图像分类（ImageNet-1k，SwinV2-T 骨干网络）、行人重识别（MSMT17，ViT-small 骨干网络）、目标检测（COCO，Mask-RCNN + Swin-T 骨干网络）和图像分割（ADE20K，FCN + ResNet-50 骨干网络）四个代表性任务上，分别测试以下四种设置：

（1）基线方法：不添加任何去噪模块的原始骨干网络。

（2）基线 + 第三章基础方法：仅使用第三章的参数融合去噪方法，不引入蒸馏和多步融合。

（3）基线 + 蒸馏模块（DM）：在第三章方法的基础上，仅添加教师--学生蒸馏增强。

（4）基线 + 融合模块（FM）：在第三章方法的基础上，仅添加多步去噪融合策略。

（5）基线 + 完整方法：同时使用蒸馏模块和融合模块，即本章所提的完整增强方法。

通过对比上述设置的性能差异，可以清晰地评估各模块的贡献，并验证两个模块之间的互补性。

4.5.2 跨任务实验设置

为全面验证本章方法的泛化能力，在第三章实验设置的基础上进一步扩展实验范围。

在图像分类任务中，除了第三章使用的数据集和骨干网络之外，进一步增加 Cifar-10[102] 数据集以及 SwinV2-S、SwinV2-B、VMamba-S、VMamba-B、ViT-S、ViT-B 等多个不同规模的骨干网络变体，以验证方法在不同模型规模下的一致性。

在目标检测任务中，除 Mask-RCNN 外，进一步在 Faster-RCNN[4]、ATSS[103]、YOLOv3[6]、DETR[22] 和 CenterNet[104] 等多种检测框架上进行实验，以验证方法的模型无关性。

在图像分割任务中，除 FCN[7] 外，增加 SegFormer[8] 模型的实验，采用 mIoU 和 B-IoU 作为评价指标。

在行人重识别任务中，进一步增加车辆重识别数据集 VehicleID[105] 上的实验，以验证方法对不同检索对象的适用性。

此外，本章还通过 t-SNE[106] 特征可视化和类内/类间距离统计分析，从特征分布的角度定量验证去噪增强的效果。所有实验的训练配置（包括硬件环境、学习率、训练轮次等）与第三章保持一致，以确保实验结果的可比性。

4.6 实验结果与分析

4.6.1 消融实验与模块贡献分析

表4.1展示了在四类代表性判别式任务上的消融实验结果，系统地评估了各增强模块的独立贡献和互补效果。

表 4.1 本章各模块在多种判别式任务上的消融实验结果
Table 4.1 Ablation study of the proposed modules on multiple discriminative tasks

任务（数据集，骨干网络，指标）	基线	+ 第三章方法	+DM	+FM	+ 完整
分类（ImageNet-1k，SwinV2-T，acc@1）	81.82%	82.13%	82.19%	82.21%	82.3
检索（MSMT17，ViT-S，mAP）	66.30%	67.33%	67.45%	67.61%	67.7
检测（COCO，Mask-RCNN Swin-T，AP）	42.80%	44.30%	44.30%	44.50%	44.7
分割（ADE20K，FCN ResNet-50，B-IoU）	34.10%	34.80%	34.90%	35.50%	35.0

从表4.1可以得出以下结论：

（1）各模块均具有独立贡献。蒸馏模块（DM）在第三章方法的基础上进一步提升了分类、检索和分割任务的性能，表明教师网络的知识能够有效校正学生去噪模块的噪声预测偏差。融合模块（FM）同样在多数任务上获得了一致的提升，且在行人重识别和目标检测任务上的提升幅度较为显著，说明多步去噪融合对于噪声累积敏感的任务更为有效。

（2）两个模块具有互补性。同时使用蒸馏模块和融合模块（完整方法）在分类、检索和检测任务上均取得了最佳性能，印证了两个模块从不同维度解决问题的互补性：蒸馏模块提升每步去噪的精度，融合模块增大有效去噪的幅度。值得注意的是，在分割任务上完整方法的 B-IoU 略低于单独融合模块，这可能与分割任务中像素级预测对去噪强度较为敏感有关，过强的去噪反而可能平滑掉部分边

界信息，该现象有待后续进一步研究。

（3）不同任务呈现不同的响应模式。分类任务的绝对提升幅度较小但稳定，而检索和密集预测任务（检测、分割）获得了更大的相对增益。合理的解释是：行人重识别需要区分细微的身份差异，目标检测和图像分割需要精确的局部特征，这些任务对特征噪声更为敏感，因此从去噪增强中获益更多。

4.6.2 跨任务泛化分析

本节在更广泛的任务、数据集和骨干网络上验证本章完整方法的泛化能力。

图像分类实验

表4.2展示了本章方法在多个分类数据集和不同规模骨干网络上的实验结果。

表 4.2 本章方法在图像分类任务上的实验结果
Table 4.2 Experimental results on image classification tasks

骨干网络	数据集	参数量	acc@1		acc@5	
			基线	+ 本章方法	基线	+ 本章方法
SwinV2-T[17]	ImageNet-1k	28M	81.82%	82.13%	95.88%	96.06%
SwinV2-S[17]	ImageNet-1k	50M	83.73%	83.97%	96.62%	96.86%
SwinV2-B[17]	ImageNet-1k	88M	84.20%	84.31%	96.93%	97.06%
VMamba-T[18]	ImageNet-1k	30M	82.38%	82.51%	95.80%	95.89%
VMamba-S[18]	ImageNet-1k	50M	83.12%	83.27%	96.04%	96.22%
VMamba-B[18]	ImageNet-1k	89M	83.83%	83.91%	96.55%	96.70%
ViT-S[13]	ImageNet-1k	22M	83.87%	84.02%	96.73%	96.86%
ViT-B[13]	ImageNet-1k	86M	84.53%	84.64%	97.15%	97.23%
ResNet-50[12]	ImageNet-1k	26M	76.13%	76.28%	92.86%	92.95%
ViT-S[13]	Cifar-10	22M	96.13%	96.20%	–	–
ViT-B[13]	Cifar-10	87M	98.02%	98.31%	–	–
ViT-B[13]	CUB200	87M	91.78%	91.99%	–	–
ViT-B[13]	Oxford-Pet	87M	94.37%	94.58%	–	–
ViT-B[13]	Flowers	87M	99.12%	99.30%	–	–

从表4.2可以观察到以下规律：

（1）本方法在 Swin Transformer、VMamba、ViT 和 ResNet 四种不同架构族的骨干网络上均取得了一致的性能提升，验证了方法的架构无关性。无论是基于卷积的 ResNet、基于自注意力的 ViT 和 Swin Transformer，还是基于状态空间模型的 VMamba，本方法均能通过特征去噪改善分类准确率。

（2）小规模骨干网络（如 SwinV2-T、VMamba-T、ViT-S）的提升幅度普遍大于大规模骨干网络（如 SwinV2-B、VMamba-B、ViT-B）。这与第三章的分析一致：参数量较小的模型提取的特征中残留更多噪声，去噪的改善空间更大。

（3）在细粒度分类数据集（CUB200、Oxford-Pet、Flowers）上也取得了显著提升，验证了方法对需要精细特征区分的任务同样有效。

目标检测实验

表4.3展示了本方法在 COCO 数据集上跨多种检测框架的实验结果。

表 4.3 本章方法在目标检测任务上的实验结果
Table 4.3 Experimental results on object detection tasks

检测方法	骨干网络	AP		AP_{50}		AP_{75}	
		基线	+ 本章方法	基线	+ 本章方法	基线	+ 本章方法
Mask-RCNN[5]	Swin-T	42.8%	44.3%	65.1%	67.1%	47.0%	48.6%
	Swin-S	48.2%	49.0%	69.9%	70.9%	52.8%	53.8%
	ResNet-50	42.6%	43.2%	63.7%	65.0%	46.4%	46.8%
Faster-RCNN[4]	ResNet-50	37.4%	38.3%	58.1%	58.8%	40.4%	41.0%
ATSS[103]	ResNet-50	39.4%	39.9%	57.6%	58.2%	42.8%	43.2%
YOLOv3[6]	DarkNet-53	27.9%	28.4%	49.2%	50.3%	28.3%	27.8%
DETR[22]	ResNet-50	39.9%	40.8%	60.4%	59.9%	41.7%	42.9%
CenterNet[104]	ResNet-50	40.2%	40.6%	58.3%	59.1%	43.9%	44.0%

实验结果表明，本方法在六种不同的检测框架上均取得了性能提升，涵盖了两阶段检测器（Mask-RCNN、Faster-RCNN）、单阶段检测器（ATSS、YOLOv3）和基于 Transformer 的检测器（DETR、CenterNet）。这些检测方法在架构设计、候选框生成方式和训练策略等方面存在显著差异，本方法仍然能够在不引入额外推理开销的前提下一致地提升检测性能，充分体现了方法的模型无关性和通用性。

图像分割实验

表4.4展示了本方法在 ADE20K 数据集上的图像分割实验结果。

表 4.4 本章方法在图像分割任务上的实验结果
Table 4.4 Experimental results on image segmentation tasks

分割方法	骨干网络	aAcc		B-IoU		mIoU	
		基线	+ 本章方法	基线	+ 本章方法	基线	+ 本章方法
FCN[7]	ResNet-50	0.774	0.779	0.287	0.299	0.359	0.365
FCN	ResNet-101	0.793	0.796	0.306	0.316	0.396	0.404
SegFormer[8]	MIT-B0	0.782	0.788	0.292	0.297	0.374	0.381
SegFormer	MIT-B1	0.812	0.816	0.341	0.348	0.422	0.425

在图像分割任务中，本方法在 FCN 和 SegFormer 两种分割模型以及不同规模的骨干网络上均取得了 mIoU 和 B-IoU 的一致提升。值得关注的是，B-IoU 指标衡量的是分割边界的精度，该指标的提升表明去噪增强后的特征具有更好的空间定位能力，能够更准确地描绘目标边界。

车辆重识别实验

为进一步验证本方法对不同检索对象的适用性，在车辆重识别数据集 VehicleID[105] 上进行实验。表4.5展示了实验结果。

表 4.5 本章方法在车辆重识别任务上的实验结果
Table 4.5 Experimental results on vehicle re-identification

方法	骨干网络	数据集	mAP	Rank-1
Vehicle-ReID[107]	ResNet-50	VehicleID	76.4%	69.1%
+ 本章方法	ResNet-50	VehicleID	77.3%	70.2%

实验结果表明，本方法在车辆重识别任务中同样取得了显著的性能提升。与行人重识别相比，车辆重识别场景中的噪声来源更加多样化，包括不同视角下的形变、光照反射和环境遮挡等，本方法仍然能够有效提升特征的判别性，进一步验证了方法的通用性。

特征可视化与统计分析

为从特征分布的角度直观理解去噪增强的效果，本节进行了 t-SNE 特征可视化和类内/类间距离统计分析。

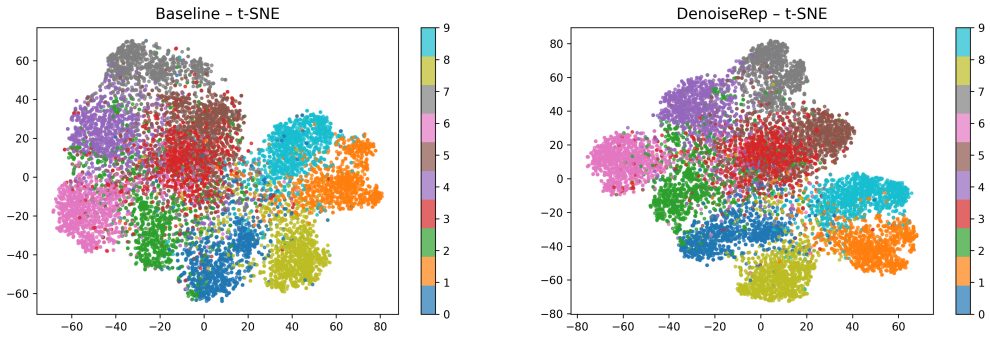

(a) 基线模型　　(b) 添加本章方法

图 4.2　Cifar-10 分类任务的 t-SNE 特征可视化对比
Fig. 4.2　t-SNE visualization of features on Cifar-10 classification

图4.2展示了基线模型和添加本章方法后的 CLS 特征在二维空间中的 t-SNE 可视化结果。可以观察到，基线模型（图4.2(a)）的特征聚类存在明显的重叠区域，不同类别的样本在边界处混杂。而添加本章方法后（图4.2(b)），各类别的聚类变得更加紧凑，类间边界明显更加清晰，表明去噪增强有效降低了特征中的噪声，提升了类别级别的判别性。

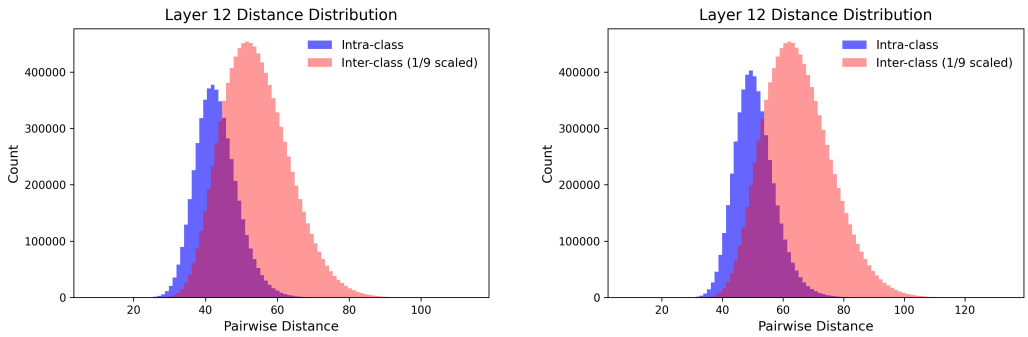

(a) 基线模型　　(b) 添加本章方法

图 4.3　类内距离与类间距离的直方图对比
Fig. 4.3　Histogram comparison of intra-class and inter-class distances

图4.3进一步展示了类内距离和类间距离分布的直方图对比。添加本章方法后，类内距离分布更加集中（方差减小），类间距离分布向更大值偏移，两个分布之间的重叠面积显著减少。

表4.6给出了定量统计结果（类内均值归一化为 1）。

表 4.6 Cifar-10 验证集上的类内/类间距离统计分析
Table 4.6 Statistical analysis of intra- and inter-class distances on Cifar-10

指标	基线	+ 本章方法
类内方差	0.019	0.017
类间均值	43.096	50.755
类间方差	54.132	64.959
类间/类内比	1.256	1.280
重叠面积	0.463	0.416

统计结果与可视化分析一致：（1）类内方差从 0.019 降低至 0.017，说明同类特征更加一致；（2）类间均值从 43.096 增加至 50.755，说明不同类别的特征被推得更远；（3）类间/类内比从 1.256 提高至 1.280，说明整体可分离性增强；（4）重叠面积从 0.463 降低至 0.416，说明类内和类间距离分布的分离程度更好。这些结果从特征几何的角度充分证明了去噪增强对表征质量的改善。

4.7 本章小结

本章针对第三章方法存在的两个核心局限——轻量去噪模块的表达能力受限和单步去噪幅度有限，提出了基于模型蒸馏的特征增强算法。主要贡献和结论如下：

（1）提出了教师--学生蒸馏去噪框架。通过引入参数量不受约束的教师去噪网络在训练阶段指导学生去噪模块的学习，有效弥补了线性去噪模块容量不足导致的噪声预测偏差。蒸馏知识在训练完成后被固化到学生模块中，因此推理阶段无需教师网络，保持了零额外推理成本的特性。

（2）设计了多步去噪融合策略。从多轮单层去噪的数学推导出发，揭示了仿射去噪操作的递归叠加规律，进而设计了多步去噪融合训练方法。通过在教师网络中执行多步去噪并将其知识蒸馏到学生模块中，在不增加推理成本的条件下实现了更大幅度的去噪效果。

（3）建立了统一的无监督与有监督去噪增强框架。将第三章的参数融合方法和本章的蒸馏增强方法统一到同一训练框架中，使之既可作为无监督的正则化手段，也可利用标签信息引导有针对性的去噪。

（4）在图像分类、行人重识别、车辆重识别、目标检测和图像分割五类判别式

任务上进行了系统实验。消融实验验证了蒸馏模块和融合模块各自的独立贡献及互补性；跨任务实验在 14 种骨干网络和 8 种下游方法上均取得了一致的性能提升；特征可视化和距离统计分析从特征几何的角度直观证明了去噪增强对表征质量的改善效果。

5 结论与展望

本文围绕基于扩散模型的图像判别任务特征增强算法展开系统研究，针对判别式视觉模型中特征噪声这一共性瓶颈问题，提出了将扩散模型的去噪能力以通用、高效的方式融入判别式表征学习的技术路线。本章首先总结全文的研究工作，然后归纳主要创新点，最后分析现有方法的局限性并展望未来研究方向。

5.1 全文工作总结

本文的研究工作围绕" 如何在不增加推理成本的前提下利用扩散模型的去噪能力提升判别式特征的质量" 这一核心问题展开，主要包括以下几个方面：

（1）第一章阐述了研究背景与意义，分析了判别式视觉任务中特征噪声的来源及其对模型性能的制约，梳理了扩散模型在判别式任务中的应用现状，指出了当前研究面临的三个关键挑战：缺乏通用的特征去噪框架、去噪过程引入不可忽视的推理开销、以及轻量化去噪模块的能力瓶颈。在此基础上，明确了本文的研究内容和技术路线。

（2）第二章对本文涉及的关键技术进行了系统综述，涵盖扩散模型的基本理论（包括前向扩散过程、反向去噪过程和训练目标）、判别式视觉任务的代表性方法（包括图像分类、行人重识别、目标检测和图像分割）、知识蒸馏技术的基本框架和发展脉络，以及结构重参数化技术的相关工作，为后续章节的算法设计提供了理论基础。

（3）第三章提出了面向无额外推理成本的特征增强算法。该方法的核心思想是将骨干网络的级联嵌入层重新解释为扩散模型的递归去噪过程，在统一框架下实现特征提取与特征去噪的联合建模。通过严格的数学推导，证明了去噪层参数可以等价地合并至原始嵌入层参数中，从而在推理阶段完全消除去噪操作带来的额外计算开销。实验结果表明，该方法在行人重识别、图像分类、目标检测和图像分割四类任务上均取得了稳定的性能提升，且具有零额外推理延迟的特性。

（4）第四章提出了基于模型蒸馏的特征增强算法，针对第三章方法存在的轻量去噪模块表达能力受限和单步去噪幅度有限两个问题，设计了两项协同增强策略。教师--学生蒸馏去噪框架通过高容量教师网络指导轻量级学生去噪模块的训练，有效提升了噪声预测精度；多步去噪融合策略通过将多步去噪轨迹压缩为等效的单步操作，在有限网络层数下增强了去噪幅度。消融实验验证了两个模块各自的独立贡献及其互补性，跨任务实验在 14 种骨干网络和 8 种下游方法上均取得了一致的性能提升。

5.2 主要创新点

本文的主要创新点归纳如下：

（1）提出了特征提取与特征去噪的统一建模框架。将骨干网络的级联嵌入层与扩散模型的递归去噪过程进行类比，建立了两者的数学对应关系。在此框架下，特征提取与去噪在网络逐层传播中同步完成，无需在骨干网络之外附加独立的去噪模块。该框架具有通用性，适用于 ResNet、ViT、Swin Transformer 和 VMamba 等多种骨干网络架构，不依赖特定任务的数据结构，可即插即用地应用于各类判别式视觉任务。

（2）设计了基于参数融合的零额外推理开销机制。通过严格的数学推导，证明了去噪层参数与嵌入层参数融合后的数学等价性，将训练阶段的双分支结构（嵌入层分支 + 去噪层分支）在推理阶段合并为与原始骨干网络结构和参数量完全相同的单分支结构。这一机制从根本上解决了扩散去噪引入额外推理开销的问题，使得去噪增强在不改变已有模型部署架构的前提下即可实现。

（3）提出了教师--学生蒸馏去噪框架与多步去噪融合策略。蒸馏框架利用高容量教师网络在训练阶段为轻量级学生去噪模块提供更精确的噪声分布估计指导，有效突破了参数融合约束下去噪模块的能力瓶颈。多步去噪融合通过数学推导揭示了仿射去噪操作的递归叠加规律，并借鉴渐进蒸馏的思想将多步去噪轨迹压缩为等效的单步操作，在有限网络层数下显著增强了去噪幅度。两项策略分别从噪声预测精度和等效去噪幅度两个维度互补增强，共同实现了更优的特征判别性。

5.3 不足与未来工作

尽管本文所提方法在多个判别式视觉任务上取得了良好的实验效果，但仍存在一些局限性，值得在未来工作中进一步探索和改进。

（1）去噪调度策略的自适应性不足。当前方法采用固定的噪声调度参数 β_t 和统一的扩散步数设置，对所有骨干网络和任务使用相同的超参数配置。然而，不同任务（如分类与分割）、不同骨干网络（如浅层与深层）以及不同层级的特征所包含的噪声特性可能存在显著差异。未来可以探索自适应去噪调度机制，根据每一层特征的噪声水平动态调整扩散步数和噪声幅度，从而实现更精细化的特征增强。

（2）对多模态和跨模态场景的探索有限。本文的实验主要聚焦于单一视觉模态的判别式任务。随着视觉--语言预训练模型（如 CLIP）和多模态大模型的快速发展，如何将所提的特征去噪方法扩展到多模态特征空间，在视觉特征与文本特征的联合表示中进行去噪增强，是一个有价值的研究方向。跨模态的特征去噪有望在零样本学习、开放词汇检测等新兴任务中发挥作用。

（3）与大规模预训练模型的结合有待深入。当前方法在中等规模的骨干网络（22M～89M 参数量）上进行了验证，尚未系统探索与数十亿参数规模的视觉基础模型的结合效果。大规模预训练模型通常具有更强的特征提取能力，其特征中残留噪声的分布特性可能与中等规模模型存在差异。未来可以研究本方法在大规模视觉基础模型上的适用性和最优配置策略。

（4）去噪过程的理论分析有待加强。虽然本文通过数学推导证明了参数融合的等价性，但对于去噪增强为何以及在何种条件下能够提升判别式特征质量的理论解释尚不充分。未来可以从信息论、统计学习理论等角度，建立去噪增强与特征判别性之间的理论联系，为方法的设计提供更坚实的理论指导。

参考文献

[1] Agarap A F. An architecture combining convolutional neural network (CNN) and support vector machine (SVM) for image classification [J]. arXiv preprint arXiv:1712.03541, 2017.

[2] Albawi S, Mohammed T A, Al-Zawi S. Understanding of a convolutional neural network [C]. In 2017 international conference on engineering and technology (ICET), 2017: 1–6.

[3] Deng L. The mnist database of handwritten digit images for machine learning research [best of the web] [J]. IEEE signal processing magazine, 2012, 29 (6): 141–142.

[4] Ren S. Faster r-cnn: Towards real-time object detection with region proposal networks [J]. arXiv preprint arXiv:1506.01497, 2015.

[5] He K, Gkioxari G, Dollár P, et al. Mask r-cnn [C]. In Proceedings of the IEEE international conference on computer vision, 2017: 2961–2969.

[6] Redmon J. Yolov3: An incremental improvement [J]. arXiv preprint arXiv:1804.02767, 2018.

[7] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2015: 3431–3440.

[8] Xie E, Wang W, Yu Z, et al. SegFormer: Simple and efficient design for semantic segmentation with transformers [J]. Advances in neural information processing systems, 2021, 34: 12077–12090.

[9] Lin K, Yang H-F, Hsiao J-H, et al. Deep learning of binary hash codes for fast image retrieval [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition workshops, 2015: 27–35.

[10] Weyand T, Araujo A, Cao B, et al. Google landmarks dataset v2-a large-scale benchmark for instance-level recognition and retrieval [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 2575–2584.

[11] Bengio Y, Courville A, Vincent P. Representation Learning: A Review and New Perspectives [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35 (8): 1798–1828.

[12] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770–778.

[13] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale [J]. arXiv preprint arXiv:2010.11929, 2020.

[14] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks [J]. Advances in neural information processing systems, 2012, 25.

[15] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86 (11): 2278–2324.

[16] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [J]. Advances in neural information processing systems, 2017, 30.

[17] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows [C]. In Proceedings of the IEEE/CVF international conference on computer vision, 2021: 10012–10022.

[18] Liu Y, Tian Y, Zhao Y, et al. Vmamba: Visual state space model [J]. arXiv preprint arXiv:2401.10166, 2024.

[19] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database [C]. In Computer Vision and Pattern Recognition, 2009: 248–255.

[20] Ye M, Shen J, Lin G, et al. Deep learning for person re-identification: A survey and outlook [J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44 (6): 2872–2893.

[21] Bedagkar-Gala A, Shah S K. A survey of approaches and trends in person re-identification [J]. Image and vision computing, 2014, 32 (4): 270–286.

[22] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers [C]. In European conference on computer vision, 2020: 213–229.

[23] Zhou B, Zhao H, Puig X, et al. Scene parsing through ade20k dataset [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 633–641.

[24] Sohl-Dickstein J, Weiss E, Maheswaranathan N, et al. Deep unsupervised learning using nonequilibrium thermodynamics [C]. In International conference on machine learning, 2015: 2256–2265.

[25] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models [J]. Advances in neural information processing systems, 2020, 33: 6840–6851.

[26] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 10684–10695.

[27] Ramesh A, Pavlov M, Goh G, et al. Zero-shot text-to-image generation [C]. In International Conference on Machine Learning, 2021: 8821–8831.

[28] Ho J, Chan W, Saharia C, et al. Imagen video: High definition video generation with diffusion models [J]. arXiv preprint arXiv:2210.02303, 2022.

[29] Hoogeboom E, Satorras V G, Vignac C, et al. Equivariant diffusion for molecule generation in 3d [C]. In International conference on machine learning, 2022: 8867–8887.

[30] Cao H, Tan C, Gao Z, et al. A Survey on Generative Diffusion Models [J]. IEEE Transactions on Knowledge and Data Engineering, 2024: 1–20.

[31] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets [J]. Advances in neural information processing systems, 2014, 27.

[32] Karras T, Laine S, Aila T. A style-based generator architecture for generative adversarial networks [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 4401–4410.

[33] Mirza M, Osindero S. Conditional generative adversarial nets [J]. arXiv preprint arXiv:1411.1784, 2014.

[34] Kingma D P, Welling M. Auto-encoding variational bayes [J]. arXiv preprint arXiv:1312.6114, 2013.

[35] Van Den Oord A, Vinyals O, et al. Neural discrete representation learning [J]. Advances in neural information processing systems, 2017, 30.

[36] Zhao T, Zhao R, Eskenazi M. Learning discourse-level diversity for neural dialog models using conditional variational autoencoders [J]. arXiv preprint arXiv:1703.10960, 2017.

[37] Saharia C, Chan W, Saxena S, et al. Photorealistic text-to-image diffusion models with deep language understanding [J]. Advances in Neural Information Processing Systems, 2022, 35: 36479–36494.

[38] Song J, Meng C, Ermon S. Denoising diffusion implicit models [J]. arXiv preprint arXiv:2010.02502, 2020.

[39] Salimans T, Ho J. Progressive distillation for fast sampling of diffusion models [J]. arXiv preprint arXiv:2202.00512, 2022.

[40] Lu C, Zhou Y, Bao F, et al. Dpm-solver: A fast ode solver for diffusion probabilistic model sampling in around 10 steps [J]. Advances in neural information processing systems, 2022, 35: 5775–5787.

[41] Chen S, Sun P, Song Y, et al. Diffusiondet: Diffusion model for object detection [C]. In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 19830–19843.

[42] Tian J, Aggarwal L, Colaco A, et al. Diffuse, attend, and segment: Unsupervised zero-shot segmentation using stable diffusion [J]. arXiv preprint arXiv:2308.12469, 2023.

[43] Li S, Sun L, Li Q. CLIP-ReID: exploiting vision-language model for image re-identification without concrete text labels [C]. In Proceedings of the AAAI Conference on Artificial Intelligence, 2023: 1405–1413.

[44] Wah C, Branson S, Welinder P, et al. The caltech-ucsd birds-200-2011 dataset [J], 2011.

[45] Parkhi O M, Vedaldi A, Zisserman A, et al. Cats and dogs [C]. In 2012 IEEE conference on computer vision and pattern recognition, 2012: 3498–3505.

[46] Nilsback M-E, Zisserman A. Automated flower classification over a large number of classes [C]. In 2008 Sixth Indian conference on computer vision, graphics & image processing, 2008: 722–729.

[47] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning [C]. In Computer Vision and Pattern Recognition, 2015: 2197–2206.

[48] Wang G, Yang S, Liu H, et al. High-Order Information Matters: Learning Relation and Topology for Occluded Person Re-Identification. [C]. 2020.

[49] Ni H, Li Y, Gao L, et al. Part-aware transformer for generalizable person re-identification [C]. In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 11280–11289.

[50] Zhang D, Yin J, Zhu X, et al. Network Representation Learning: A Survey [J]. IEEE Transactions on Big Data, 2020, 6 (1): 3–28.

[51] Xu P, Hayet J-B, Karamouzas I. Socialvae: Human trajectory prediction using timewise latents [C]. In European Conference on Computer Vision, 2022: 511–528.

[52] Nichol A Q, Dhariwal P. Improved denoising diffusion probabilistic models [J]. International Conference on Machine Learning, 2021: 8162–8171.

[53] Dhariwal P, Nichol A. Diffusion models beat GANs on image synthesis [J]. Advances in neural information processing systems, 2021, 34: 8780–8794.

[54] Song Y, Sohl-Dickstein J, Kingma D P, et al. Score-based generative modeling through stochastic differential equations [J]. International Conference on Learning Representations, 2021.

[55] Peebles W, Xie S. Scalable diffusion models with transformers [C]. In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 4195–4205.

[56] Lipman Y, Chen R T, Ben-Hamu H, et al. Flow matching for generative modeling [J]. International Conference on Learning Representations, 2023.

[57] Gu S, Chen D, Bao J, et al. Vector quantized diffusion model for text-to-image synthesis [C]. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 10696–10706.

[58] Law H, Deng J. Cornernet: Detecting objects as paired keypoints [C]. In Proceedings of the European conference on computer vision (ECCV), 2018: 734–750.

[59] Radosavovic I, Kosaraju R P, Girshick R, et al. Designing network design spaces [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 10428–10436.

[60] Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks [C]. In International conference on machine learning, 2019: 6105–6114.

[61] Liu Z, Mao H, Wu C-Y, et al. A ConvNet for the 2020s [C]. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 11976–11986.

[62] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention [C]. In International conference on machine learning, 2021: 10347–10357.

[63] He K, Chen X, Xie S, et al. Masked autoencoders are scalable vision learners [C]. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 16000–16009.

[64] Oquab M, Darcet T, Moutakanni T, et al. DINOv2: Learning robust visual features without supervision [J]. Transactions on Machine Learning Research, 2024.

[65] Ma B, Su Y, Jurie F. Covariance descriptor based on bio-inspired features for person re-identification and face verification [J]. Image and Vision Computing, 2014, 32 (6-7): 379–390.

[66] Yang Y, Yang J, Yan J, et al. Salient color names for person re-identification [C]. In European conference on computer vision, 2014: 536–551.

[67] Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints [C]. In Computer Vision and Pattern Recognition, 2012: 2288–2295.

[68] Liao S, Li S Z. Efficient psd constrained asymmetric metric learning for person re-identification [C]. In International Conference on Computer Vision, 2015: 3685–3693.

[69] Zheng W-S, Gong S, Xiang T. Reidentification by relative distance comparison [J]. IEEE transactions on pattern analysis and machine intelligence, 2013, 35 (3): 653–668.

[70] Cho Y, Kim W J, Hong S, et al. Part-based pseudo label refinement for unsupervised person re-identification [C]. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 7308–7318.

[71] Fu D, Chen D, Bao J, et al. Unsupervised pre-training for person re-identification [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 14750–14759.

[72] Wang B, Yang Y, Wu J, et al. Self-similarity Driven Scale-invariant Learning for Weakly Supervised Person Search [J]. arXiv preprint arXiv:2302.12986, 2023.

[73] Wang G, Yang Y, Cheng J, et al. Color-sensitive person re-identification [C]. In International Joint Conference on Artificial Intelligence, 2019: 933–939.

[74] Li J, Zhang S, Xiong H, et al. AutoST: Towards the Universal Modeling of Spatio-temporal Sequences [J]. Advances in Neural Information Processing Systems, 2022, 35: 20498–20510.

[75] Li J, Liu Y, Zou L. DynGCN: A dynamic graph convolutional network based on spatial-temporal modeling [C]. In Web Information Systems Engineering–WISE 2020: 21st International Conference, Amsterdam, The Netherlands, October 20–24, 2020, Proceedings, Part I 21, 2020: 83–95.

[76] Chen Y, Li W, Sakaridis C, et al. Domain adaptive faster r-cnn for object detection in the wild [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 3339–3348.

[77] Ding X, Zhang X, Ma N, et al. Repvgg: Making vgg-style convnets great again [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 13733–13742.

[78] Baranchuk D, Rubachev I, Voynov A, et al. Label-efficient semantic segmentation with diffusion models [C]. In International Conference on Learning Representations, 2022.

[79] Li A C, Prabhudesai M, Duggal S, et al. Your diffusion model is secretly a zero-shot classifier [C]. In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 2206–2217.

[80] Song Y, Dhariwal P, Chen M, et al. Consistency models [C]. In International Conference on Machine Learning, 2023: 32211–32252.

[81] Luo S, Tan Y, Huang L, et al. Latent consistency models: Synthesizing high-resolution images with few-step inference [J]. arXiv preprint arXiv:2310.04378, 2023.

[82] Liu X, Gong C, Liu Q. Flow straight and fast: Learning to generate and transfer data with rectified flow [J]. International Conference on Learning Representations, 2023.

[83] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network [J]. arXiv preprint arXiv:1503.02531, 2015.

[84] Romero A, Ballas N, Kahou S E, et al. FitNets: Hints for thin deep nets [J]. International Conference on Learning Representations, 2015.

[85] Tian Y, Krishnan D, Isola P. Contrastive representation distillation [C]. In International Conference on Learning Representations, 2020.

[86] Luo H, Wang P, Xu Y, et al. Self-supervised pre-training for transformer-based person re-identification [J]. arXiv preprint arXiv:2111.12084, 2021.

[87] Xu Z, Wang G, Huang X, et al. Denoiserep: Denoising model for representation learning [J]. arXiv preprint arXiv:2406.08773, 2024.

[88] Zheng Z, Zheng L, Yang Y. Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro [J]. arXiv preprint arXiv:1701.07717, 2017.

[89] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark [C]. In International Conference on Computer Vision, 2015: 1116–1124.

[90] Wei L, Zhang S, Gao W, et al. Person transfer gan to bridge domain gap for person re-identification [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 79–88.

[91] Li W, Zhao R, Xiao T, et al. Deepreid: Deep filter pairing neural network for person re-identification [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2014: 152–159.

[92] Karpathy A, Fei-Fei L. Deep visual-semantic alignments for generating image descriptions [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2015: 3128–3137.

[93] Wang G, Yuan Y, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification [C]. In Proceedings of the 26th ACM international conference on Multimedia, 2018: 274–282.

[94] Zhou K, Yang Y, Cavallaro A, et al. Omni-scale feature learning for person re-identification [C]. In Proceedings of the IEEE/CVF international conference on computer vision, 2019: 3702–3712.

[95] Fang P, Zhou J, Roy S K, et al. Bilinear attention networks for person retrieval [C]. In Proceedings of the IEEE/CVF international conference on computer vision, 2019: 8030–8039.

[96] Chen T, Ding S, Xie J, et al. Abd-net: Attentive but diverse person re-identification [C]. In Proceedings of the IEEE/CVF international conference on computer vision, 2019: 8351–8361.

[97] Zhang Z, Lan C, Zeng W, et al. Relation-aware global attention for person re-identification [C]. In Proceedings of the ieee/cvf conference on computer vision and pattern recognition, 2020: 3186–3195.

[98] Zhu K, Guo H, Liu Z, et al. Identity-guided human semantic parsing for person re-identification [C]. In European Conference on Computer Vision, 2020: 346–363.

[99] Li H, Wu G, Zheng W-S. Combined depth space based architecture search for person re-identification [C]. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 6729–6738.

[100] Wang H, Shen J, Liu Y, et al. NFormer: Robust Person Re-identification with Neighbor Transformer [C]. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 7297–7307.

[101] He S, Luo H, Wang P, et al. TransReID: Transformer-Based Object Re-Identification [C]. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), October 2021: 15013–15022.

[102] Krizhevsky A, Hinton G, et al. Learning multiple layers of features from tiny images [J], 2009.

[103] Zhang S, Chi C, Yao Y, et al. Bridging the gap between anchor-based and anchor-free detection via adaptive training sample selection [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 9759–9768.

[104] Zhou X, Wang D, Krähenbühl P. Objects as points [J]. arXiv preprint arXiv:1904.07850, 2019.

[105] Liu H, Tian Y, Yang Y, et al. Deep relative distance learning: Tell the difference between similar vehicles [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 2167–2175.

[106] Maaten L v d, Hinton G. Visualizing data using t-SNE [J]. Journal of machine learning research, 2008, 9 (Nov): 2579–2605.

[107] Chu R, Sun Y, Li Y, et al. Vehicle re-identification with viewpoint-aware metric learning [C]. In Proceedings of the IEEE/CVF international conference on computer vision, 2019: 8282–8291.

[108] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline) [C]. In European Conference on Computer Vision, 2018: 480–496.

[109] Wang G, Zhang T, Cheng J, et al. RGB-Infrared Cross-Modality Person Re-Identification via Joint Pixel and Feature Alignment [C]. In International Conference on Computer Vision, 2019: 3622–3631.

[110] Wang G, Zhang T, Yang Y, et al. Cross-Modality Paired-Images Generation for RGB-Infrared Person Re-Identification [C]. In AAAI Conference on Artificial Intelligence, 2020.

[111] Zheng L, Yang Y, Hauptmann A G. Person re-identification: Past, present and future [J]. arXiv preprint arXiv:1610.02984, 2016.

[112] Umer S, Sardar A, Dhara B C, et al. Person identification using fusion of iris and periocular deep features [J]. Neural Networks, 2020, 122: 407–419.

[113] Tang Y, Yang X, Wang N, et al. Person Re-Identification with Feature Pyramid Optimization and Gradual Background Suppression [J]. Neural Networks, 2020, 124: 223–232.

[114] Wu J, Yang Y, Lei Z, et al. An end-to-end exemplar association for unsupervised person Re-identification [J]. Neural Networks, 2020, 129: 43–54.

[115] Wang G, Zhang T, Cheng J, et al. RGB-Infrared Cross-Modality Person Re-Identification via Joint Pixel and Feature Alignment [C]. In In Proceedings of the 2019 IEEEInternational Conference on Computer Vision (ICCV), 2019: 3622–3631.

[116] Wang G, Zhang T, Yang Y, et al. Cross-Modality Paired-Images Generation for RGB-Infrared Person Re-Identification [C]. In In Proceedings of the Thirty-Fourth AAAI Conference on Artificial Intelligence, 2020.

[117] Wang G, Yang S, Liu H, et al. High-Order Information Matters: Learning Relation and Topology for Occluded Person Re-Identification. [J]. In Proceedings of the 2020 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2020.

[118] Wang G, Yang Y, Zhang T, et al. Cross-modality paired-images generation and augmentation for RGB-infrared person re-identification [J]. Neural Networks, 2020, 128: 294–304.

附录 A

附录标题

[内容为五号宋体。] 附录是作为论文主体的补充项目，并不是必须的。论文的附录依序用大写正体英文字母 A、B、C……编序号，如：附录 A。

索引

[内容为五号宋体。] 按照需要编排分类索引、著者索引、关键词索引等。

作者简历及攻读硕士学位期间取得的研究成果

一、作者简历

2009 年，毕业于 XX 大学，XX 学院，XX 专业，获 XX 学士；

2009 年至 2010 年，就读于 XX 大学，XX 学院，XX 专业，导师 XX 教授；

2010 年至今，于 XX 大学，XX 实验室，XX 专业攻读博士学位，导师 XX 教授。

二、发表论文

[1] XXX, Truncated adaptation design for decentralized neural dynamic surface control of interconnected nonlinear systems under input saturation, *International Journal of Control*, Volume 89, Issue 7, pp: 1447-1466, 2016. (SCI)

[2] XXX, Lei Chen, Neural adaptive coordination control of multiple trains under bidirectional communication topology, *Neural Computing and Applications*, Volume 27, Issue 8, pp: 2497-2507, 2016. (SCI)

[3] XXX, Neural adaptive control for uncertain MIMO systems with constrained input via intercepted adaptation and single learning parameter approach, *Nonlinear Dynamics*, Volume 82, Issue 3, pp: 1109-1126, 2015. (SCI)

三、参与科研项目

[1]

[2]

[3]

四、专利

[1]

[2]

[3]

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名： 签字日期： 年 月 日

学位论文数据集

表 1.1 数据集页

<table>
<tr><td>关键词 *</td><td>密级 *</td><td>中图分类号</td><td>UDC</td><td>论文资助</td></tr>
<tr><td></td><td></td><td></td><td></td><td></td></tr>
<tr><td colspan="2">学位授予单位名称 *</td><td>学位授予单位代码 *</td><td>学位类别 *</td><td>学位级别 *</td></tr>
<tr><td colspan="2">北京交通大学</td><td>10004</td><td></td><td></td></tr>
<tr><td colspan="2">论文题名 *</td><td colspan="2">并列题名</td><td>论文语种 *</td></tr>
<tr><td colspan="2"></td><td colspan="2"></td><td></td></tr>
<tr><td>作者姓名 *</td><td colspan="2"></td><td>学号 *</td><td></td></tr>
<tr><td colspan="2">培养单位名称 *</td><td>培养单位代码 *</td><td>培养单位地址</td><td>邮编</td></tr>
<tr><td colspan="2">北京交通大学</td><td>10004</td><td>北京市海淀区西直门外上园村 3 号</td><td>100044</td></tr>
<tr><td colspan="2">学科专业 *</td><td>研究方向 *</td><td>学制 *</td><td>学位授予年 *</td></tr>
<tr><td colspan="2"></td><td></td><td></td><td></td></tr>
<tr><td>论文提交日期 *</td><td colspan="4"></td></tr>
<tr><td>导师姓名 *</td><td colspan="2"></td><td>职称 *</td><td></td></tr>
<tr><td>评阅人</td><td colspan="2">答辩委员会主席</td><td colspan="2">答辩委员会成员</td></tr>
<tr><td></td><td colspan="2"></td><td colspan="2"></td></tr>
<tr><td colspan="5">电子版论文提交格式 文本 () 图像 () 视频 () 音频 () 多媒体 () 其他 ()
推荐格式：application/msword; application/pdf</td></tr>
<tr><td colspan="2">电子版论文出版（发布）者</td><td colspan="2">电子版论文出版（发布）地</td><td>权限声明</td></tr>
<tr><td colspan="2"></td><td colspan="2"></td><td></td></tr>
<tr><td>论文总页数 *</td><td colspan="4"></td></tr>
<tr><td colspan="5">共 33 项，其中带 * 为必填数据，为 21 项。</td></tr>
</table>